

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет Высшая школа бизнеса

Биксалин Артём Ильнурович

**Автоматизация бизнес-процессов промышленной компании с
использованием больших языковых моделей**

Выпускная квалификационная работа
по направлению подготовки Бизнес-информатика
образовательная программа «38.03.05 Бизнес-информатика»

Научный руководитель
Профессор департамента
бизнес-информатики ВШБ НИУ ВШЭ



Попов Виктор Юрьевич

Москва 2026

Оглавление

Оглавление	2
Перечень сокращений	4
Глоссарий.....	6
ВВЕДЕНИЕ	8
Глава 1. Выявление бизнес-проблемы и обзор лучших практик....	11
1.1. Описание компании и контекст задачи	11
1.2. Анализ внешней среды (PEST-анализ).....	15
1.3. Анализ внутренней среды (SWOT-анализ).....	16
1.4. Анализ текущего процесса (AS-IS)	19
1.5. Обзор подходов к автоматизации анализа текстовых данных	24
1.6. Требования к информационной безопасности при использовании LLM	28
1.7. Стратегические альтернативы и обоснование выбора.....	29
1.8. Выводы по Главе 1	33
Глава 2. Проектирование информационно-аналитической системы	35
2.1. Формирование требований к системе.....	35
2.2. Проектирование архитектуры системы.....	38
2.3. Модель целевого бизнес-процесса (TO-BE)	46
2.4. Проектирование алгоритма обработки данных	48
2.5. Проектирование структуры хранилища данных.....	51
2.6. Экономическое обоснование.....	54
2.7. Управление рисками проекта	57

2.8. Ключевые показатели эффективности	60
2.9. Выводы по Главе 2	62
Глава 3. Реализация системы и экспериментальная оценка.....	63
3.1. Реализация конвейера обработки данных.....	63
3.2. Методика сравнительного эксперимента	63
3.3. Результаты сравнительного эксперимента	65
3.4. Демонстрация работы системы	70
3.5. Анализ результатов и обсуждение.....	70
3.6. Выводы по Главе 3	71
Заключение.....	73
Список литературы	76
Приложения	81
ПРИЛОЖЕНИЕ Б.....	84
ПРИЛОЖЕНИЕ В.....	88
ПРИЛОЖЕНИЕ Г	91

Перечень сокращений

В настоящей работе используются следующие сокращения и аббревиатуры. Сокращения приводятся в алфавитном порядке: сначала русскоязычные, затем англоязычные.

БД — база данных

ВКР — выпускная квалификационная работа

ИАС — информационно-аналитическая система

ИБ — информационная безопасность

ИТ — информационные технологии

ОС — образовательный стандарт

ПДн — персональные данные

ПК — профессиональная компетенция

УК — универсальная компетенция

ФЗ — федеральный закон

ФОТ — фонд оплаты труда

API — Application Programming Interface (программный интерфейс)

AS-IS — модель текущего состояния процесса

BERT — Bidirectional Encoder Representations from Transformers

BPMN — Business Process Model and Notation

C4 — нотация архитектурных диаграмм (Context, Container, Component, Code)

DWH — Data Warehouse (хранилище данных)

ER — Entity-Relationship (модель «сущность-связь»)

F1 — F-мера, гармоническое среднее точности и полноты

FR — Functional Requirement (функциональное требование)

GPT — Generative Pre-trained Transformer

GPU — Graphics Processing Unit (графический процессор)

JSON — JavaScript Object Notation (формат обмена данными)

KPI — Key Performance Indicator (ключевой показатель эффективности)

LLM — Large Language Model (большая языковая модель)

LMS — Learning Management System (система управления обучением)

MapReduce — паттерн распределённой обработки данных

MVP — Minimum Viable Product (минимально жизнеспособный продукт)

NFR — Non-Functional Requirement (нефункциональное требование)

NLP — Natural Language Processing (обработка естественного языка)

NPS — Net Promoter Score (индекс потребительской лояльности)

OMS — Order Management System (система управления заказами)

PEST — Political, Economic, Social, Technological (анализ макросреды)

REST — Representational State Transfer (архитектурный стиль API)

ROI — Return on Investment (возврат инвестиций)

ROUGE — Recall-Oriented Understudy for Gisting Evaluation (метрика оценки текстов)

SQL — Structured Query Language (язык структурированных запросов)

SWOT — Strengths, Weaknesses, Opportunities, Threats (анализ сильных и слабых сторон, возможностей и угроз)

TCO — Total Cost of Ownership (совокупная стоимость владения)

TF-IDF — Term Frequency – Inverse Document Frequency

TO-BE — модель целевого состояния процесса

TOWS — Threats, Opportunities, Weaknesses, Strengths (полиментная матрица стратегического анализа)

UML — Unified Modeling Language (унифицированный язык моделирования)

VRAM — Video RAM (видеопамять)

Глоссарий

В настоящей работе используются специальные термины из области информационных технологий и машинного обучения. Ниже приведены определения ключевых терминов в порядке, удобном для чтения основного текста работы.

Большая языковая модель (LLM) — нейросетевая модель, обученная на больших объёмах текста, способная генерировать связный текст в ответ на текстовый запрос. Современные LLM построены на архитектуре трансформера.

Векторное представление (embedding) — отображение слова, фразы или текста в многомерное числовое пространство, в котором семантически близкие объекты находятся близко друг к другу.

Дашборд (dashboard) — интерактивная панель визуализации данных, объединяющая ключевые показатели и графики в едином интерфейсе.

Дообучение (fine-tuning) — процесс адаптации предварительно обученной языковой модели к конкретной задаче или домену с использованием размеченного набора данных.

Инсайт — аналитический вывод, формулируемый на основе обработки данных и имеющий практическую применимость для принятия управленческих решений.

Контекстное окно (context window) — максимальное количество токенов, которое языковая модель способна обработать в рамках одного запроса. Превышение контекстного окна приводит к необходимости разбиения данных на пакеты.

Конвейер обработки (pipeline) — последовательность этапов обработки данных, организованная как единый процесс с чётко определёнными входами и выходами на каждом этапе.

MapReduce — парадигма параллельной обработки больших объёмов данных, состоящая из двух фаз: Map (разбиение задачи на подзадачи и их обработка) и Reduce (агрегация промежуточных результатов в итоговый).

Облачное развёртывание (cloud deployment) — размещение программного обеспечения на серверах внешнего провайдера с доступом через интернет; в случае LLM подразумевает передачу данных на серверы провайдера.

Промпт (prompt) — текстовая инструкция, задающая поведение языковой модели и определяющая формат ожидаемого ответа.

Промпт-инжиниринг (prompt engineering) — практика проектирования и итеративного улучшения промптов с целью получения от LLM ответов требуемого качества.

Пакетирование (batching) — разбиение большого массива данных на пакеты (batches) для последовательной обработки. Автоматическое пакетирование (auto-batching) — определение оптимального размера пакета программно, на основе характеристик модели и данных.

Размеченные данные — набор данных, для каждого элемента которого указано истинное значение целевой переменной (например, тональность отзыва), используемый для обучения и оценки моделей машинного обучения.

Тональность (sentiment) — эмоциональная окраска текста, обычно классифицируемая как позитивная, негативная или нейтральная.

Токен (token) — минимальная единица текста, обрабатываемая языковой моделью; в зависимости от токенизатора может соответствовать слову, части слова или отдельному символу.

Self-hosted развёртывание — размещение программного обеспечения на собственной инфраструктуре компании; для LLM — развёртывание модели на корпоративных GPU без передачи данных внешним провайдерам.

Reasoning-модель — специализированная разновидность LLM, генерирующая развёрнутую цепочку промежуточных рассуждений (chain-of-thought) перед формулированием итогового ответа. Эффективна для задач логического вывода, но менее эффективна для простой классификации.

Zero-shot режим — выполнение задачи языковой моделью на основе текстовой инструкции без предварительного обучения на размеченных примерах данной задачи.

Few-shot режим — выполнение задачи языковой моделью на основе нескольких примеров (обычно 2–10), включённых непосредственно в промпт.

Macro F1 — усреднённая по классам F1-мера, при расчёте которой каждый класс вносит равный вклад вне зависимости от его размера в выборке. Используется как сбалансированная метрика качества классификации на несбалансированных данных.

ВВЕДЕНИЕ

У логистических e-commerce компаний с каждым годом копится всё больше текстовых данных, которые никто толком не разбирает. Это и клиентские отзывы из OMS, и обращения в службу поддержки, и переписка курьеров в рабочих Telegram-чатах. По наблюдениям автора, объёмы такой обратной связи растут заметно быстрее, чем штат аналитиков, способный её прочитать. В итоге компания тратит часы на ручной разбор и всё равно упускает важные сигналы — от ежедневных операционных проблем до стратегических трендов спроса. Сегодня партия в 200–500 отзывов отнимает у аналитика 6–8 рабочих часов, при этом два разных сотрудника часто ставят разные категории одной и той же жалобе.

Актуальность работы обусловлена тремя причинами. Во-первых, поток обратной связи каждый год растёт быстрее, чем штат аналитиков. Во-вторых, бизнесу важно разбираться с инцидентами не за неделю, а за пару часов — иначе негативные тренды успевают перерасти в репутационные потери. В-третьих, по 152-ФЗ персональные данные граждан РФ нельзя свободно отправлять в OpenAI или Anthropic — их обработку приходится держать внутри инфраструктуры компании. Все три фактора вместе и формируют запрос на собственное self-hosted LLM-решение, которое предлагается в настоящей работе.

Цель данного исследования заключается в проектировании и разработке информационно-аналитической системы (ИАС) для автоматизированного мульти-источникового анализа обратной связи в компании электронной коммерции на основе больших языковых моделей.

Объект исследования: бизнес-процесс анализа обратной связи в компании электронной коммерции, охватывающий клиентские отзывы и внутренние коммуникации курьеров.

Предмет исследования: методы и технологии автоматизации операционной аналитики на основе больших языковых моделей.

Для достижения поставленной цели необходимо решить следующий комплекс задач:

1. Проанализировать текущий процесс анализа обратной связи (AS-IS) и выявить корневые причины его неэффективности с использованием BPMN-моделирования и диаграммы Исикавы.
2. Провести обзор существующих подходов к автоматизации анализа текстовых данных, включая традиционные методы NLP и современные большие языковые модели.
3. Сформулировать функциональные и нефункциональные требования к целевой информационно-аналитической системе.
4. Спроектировать архитектуру системы в нотациях ArchiMate, C4 и UML, включая адаптивный конвейер автоматического пакетирования по схеме MapReduce.
5. Реализовать программный прототип LLM-конвейера на Python, аналитический дашборд на Streamlit и Telegram-бот на aiogram 3.
6. Провести сравнительный эксперимент семи моделей анализа тональности (TF-IDF + XGBoost, YandexGPT Pro, YandexGPT Embeddings, YandexGPT Classifier, Qwen 2.5 7B, DeepSeek LLM 7B, DeepSeek R1 7B) на сбалансированной выборке отзывов.
7. Рассчитать годовой экономический эффект внедрения системы и сформировать реестр проектных рисков с системой ключевых показателей эффективности.
8. Сформулировать рекомендации по безопасному развёртыванию LLM в корпоративной среде с учётом требований 152-ФЗ.

Теоретико-методологическую основу исследования составили труды отечественных и зарубежных авторов по направлениям трансформерных архитектур (А. Vaswani, J. Devlin, Т. Brown), методам анализа тональности русскоязычного текста (У. Kuratov, S. Smetanin), теории информационно-аналитических систем и реинжиниринга бизнес-процессов (С.Н. Брускин,

Г.Н. Калянов, Ю.Ф. Телнов), а также стандарты ArchiMate, BPMN 2.0 и C4 Model.

Практическая значимость работы состоит в разработке функционального прототипа ИАС, позволяющего логистической e-commerce компании сократить трудозатраты на анализ обратной связи в 7,4 раза, обеспечить охват анализа близкий к 100 % (включая ранее игнорируемые курьерские чаты) и перейти от реактивной к проактивной аналитике с автоматическими алертами при выявлении критических изменений. Полученный фреймворк применим в компаниях электронной коммерции и сервис-ориентированных организациях при соблюдении требований Федерального закона № 152-ФЗ «О персональных данных».

Глава 1 посвящена выявлению бизнес-проблемы и обзору лучших практик. Рассмотрены особенности текущего процесса анализа обратной связи в компании электронной коммерции, проведён анализ корневых причин с использованием диаграммы Исикавы, выполнен обзор подходов к автоматизации текстового анализа (от TF-IDF до современных LLM), сформулированы требования к информационной безопасности при использовании языковых моделей.

Глава 2 содержит проектирование информационно-аналитической системы. Сформулированы функциональные и нефункциональные требования, спроектирована четырёхслойная архитектура в нотациях ArchiMate, C4 и UML, разработана целевая модель бизнес-процесса (TO-BE) и информационная модель данных. Приведено экономическое обоснование внедрения, реестр рисков проекта и система ключевых показателей эффективности.

Глава 3 описывает реализацию системы и сравнительную оценку моделей. Представлены программная реализация LLM-конвейера с автоматическим пакетированием, методика и результаты сравнительного эксперимента семи моделей на сбалансированной выборке RuReviews, промпт-инжиниринг и анализ полученных результатов.

Глава 1. Выявление бизнес-проблемы и обзор лучших практик

1.1. Описание компании и контекст задачи

Проект реализован в операционной среде крупной российской платформы электронной коммерции, ежедневно обрабатывающей значительный объём клиентских заказов. Компания управляет мультикатегорийным онлайн-маркетплейсом с развитой логистической сетью, включающей как собственных, так и привлечённых курьеров службы доставки. Масштаб операций генерирует непрерывный поток неструктурированных текстовых данных из двух основных источников: клиентские отзывы, оставляемые через систему управления заказами после завершения доставки, и внутренние коммуникации курьерского персонала, осуществляемые через групповые чаты в мессенджере Telegram.

Организационная структура, релевантная для данного проекта, охватывает несколько подразделений, потребляющих аналитику обратной связи в различных функциональных контекстах. Команда продуктового управления нуждается в инсайтах о проблемах пользовательского опыта, вопросах юзабилити интерфейса и жалобах, связанных с функциональностью платформы, для приоритизации дорожной карты продуктовой разработки. Отдел операционного управления осуществляет мониторинг метрик качества сервиса, показателей доставки и повторяющихся операционных проблем для реализации корректирующих мер. Логистическое подразделение отслеживает проблемы, связанные с курьерами, неэффективность маршрутов и вопросы координации складских операций для оптимизации процесса доставки. Высшее руководство опирается на агрегированные тренды тональности и рейтинги проблем при принятии стратегических решений.

Несмотря на общую потребность в аналитике обратной связи со стороны различных подразделений, единая система сбора, обработки и распределения инсайтов из клиентской и операционной обратной связи отсутствует. Каждое подразделение самостоятельно и эпизодически

анализирует фрагменты доступных данных, что приводит к дублированию усилий, противоречивым выводам и значительным задержкам между возникновением проблемы и управленческой реакцией.




Рисунок 1. Модель бизнес-кооперации AS-IS (ArchiMate Business Cooperation View)

Диаграмма бизнес-кооперации AS-IS (Рисунок 1) показывает текущее состояние работы с обратной связью в нотации ArchiMate Business Cooperation View. На стратегическом слое представлены три ключевые способности (Capability): «Аналитика клиентского опыта», «Раннее выявление операционных инцидентов» и «Управление качеством сервиса доставки». В AS-IS-состоянии эти способности реализуются ограниченно, через ручную цепочку бизнес-процессов: чтение отзывов и чатов вручную — субъективная категоризация в Excel — сведение в статичный отчёт — передача отчёта руководителю — реактивный отклик на жалобы. Бизнес-сервисы AS-IS (статичный Excel-отчёт, эпизодический разбор топ-проблем, личные рекомендации руководителя, реактивный ответ на жалобу) обслуживают трёх бизнес-акторов: менеджера по качеству, руководителя логистики и продуктовую команду. Длительность ручной обработки 200–500 отзывов составляет 6–8 часов; способность «Раннее выявление операционных инцидентов» фактически не покрыта — реакция возникает постфактум, после жалоб клиентов. Это формирует ключевое ограничение, мотивирующее переход к автоматизированному решению, рассматриваемому в Главе 2.

Как показано на Рисунке 1, отсутствие централизованной аналитической системы приводит к фрагментированной и непоследовательной обработке обратной связи между подразделениями, что подтверждает необходимость создания единой мульти-источниковой ИАС.

1.2. Анализ внешней среды (PEST-анализ)

Для оценки внешних факторов, влияющих на проект внедрения информационно-аналитической системы анализа обратной связи на основе больших языковых моделей, проведён PEST-анализ. Данный инструмент стратегического анализа классифицирует факторы макросреды по четырём группам — политические (Political), экономические (Economic), социальные (Social) и технологические (Technological) — и широко применяется в практике стратегического менеджмента и формирования бизнес-кейсов цифровой трансформации [47; 49]. Результаты анализа представлены в Таблице 1.1.

Таблица 1.1. Результаты PEST-анализа проекта внедрения ИАС

Категория	Фактор	Тип влияния	Степень
Политические	Государственная поддержка импортозамещения в ИТ (Постановление Правительства РФ № 1236, реестр отечественного ПО)	Возможность	Высокая
	Регулирование персональных данных (ФЗ-152): требование локализации обработки в РФ	Угроза / возможность	Критическая
	Развитие законодательства в сфере ИИ (проект ФЗ «О технологиях искусственного интеллекта»)	Возможность	Средняя
Экономические	Удорожание GPU-инфраструктуры вследствие санкционных ограничений (рост цен на NVIDIA через серый импорт на 40–60%)	Угроза	Высокая
	Сжатие потребительского спроса в e-commerce — повышение ценности удержания клиентов через NPS-аналитику	Возможность	Высокая
	Курсовая нестабильность рубля — удорожание облачных зарубежных сервисов	Угроза	Средняя
Социальные	Растущие ожидания клиентов от персонализации сервиса (по данным Nielsen, 71% потребителей ожидают	Возможность	Высокая

	персонализированных коммуникаций)		
	Дефицит ML/NLP-инженеров на рынке труда (HeadHunter 2025: ~3 кандидата на ML-вакансию)	Угроза	Средняя
	Тренд на работу с обратной связью как с источником операционных инсайтов в крупных российских ритейлерах (Wildberries, Ozon)	Возможность	Высокая
Технологические	Прорыв в open-source LLM: модели Qwen 2.5, DeepSeek, Llama 3 достигают качества коммерческого GPT-3.5 при self-hosted развёртывании	Возможность	Критическая
	Развитие отечественных облачных LLM (YandexGPT, GigaChat) — снижение зависимости от зарубежных API	Возможность	Высокая
	Стандартизация инструментов MLOps (Ollama, vLLM, LangChain) упрощает self-hosted развёртывание	Возможность	Высокая

Выводы по PEST-анализу. Внешняя среда благоприятна для запуска проекта: совпадение государственной политики импортозамещения, прорыва в качестве open-source LLM и роста значимости клиентской аналитики формирует «окно возможностей». Главные внешние ограничения — требования ФЗ-152, диктующие необходимость on-premise обработки персональных данных, и удорожание GPU-инфраструктуры — учитываются при выборе технологического стека (self-hosted Ollama на корпоративной GPU-инфраструктуре + отечественный YandexGPT в качестве резервного облачного контура).

1.3. Анализ внутренней среды (SWOT-анализ)

Для оценки внутренних возможностей и ограничений компании при реализации проекта проведён SWOT-анализ — классический инструмент стратегического анализа, объединяющий оценку сильных (Strengths) и

слабых (Weaknesses) сторон организации с возможностями (Opportunities) и угрозами (Threats) внешней среды [48; 52]. Результаты представлены в Таблице 1.2.

Таблица 1.2. SWOT-анализ компании в контексте проекта

Сильные стороны (Strengths) S1. Существующая система управления заказами (OMS) с накопленной базой клиентских отзывов — готовый источник данных без необходимости в дополнительной интеграции. S2. Корпоративные Telegram-каналы курьеров — уникальный источник операционной обратной связи в реальном времени, не доступный конкурентам. S3. Наличие GPU-серверов в компании (используются для рендеринга маркетинговых материалов) — могут быть переиспользованы для self-hosted LLM в нерабочее время. S4. Кросс-функциональная команда ВІ и ІТ с опытом интеграции внутренних систем — снижает риск технической реализации.	Слабые стороны (Weaknesses) W1. Отсутствие in-house экспертизы в области ML/NLP — все аналитики работают с Excel и SQL, нет компетенций по работе с LLM. W2. Реактивный режим аналитики: проблемы выявляются после жалоб клиентов, а не превентивно. W3. Аналитика основана на ручном поиске по ключевым словам, не учитывающем семантический контекст и сарказм. W4. Отсутствие выстроенного процесса обработки неструктурированных текстовых данных.
---	--

Возможности (Opportunities)	Угрозы (Threats)
O1. Доступность open-source LLM с качеством коммерческого уровня (Qwen 2.5, DeepSeek, Llama 3) — позволяет реализовать систему без зависимости от платных API. O2. Государственная поддержка ИТ-проектов в РФ: налоговые льготы, гранты РФРИТ, упрощённое включение в реестр отечественного ПО. O3. Тренд на «проактивную аналитику» и работу с инсайтами становится отраслевым стандартом в e-commerce. O4. Возможность стать референс-кейсом в отрасли логистики, использовать как маркетинговое преимущество.	T1. Возможное ужесточение Ф3-152 в части облачной обработки персональных данных — может ограничить использование облачных LLM-сервисов. T2. Геополитические риски ограничения доступа к Telegram API — может потребовать миграции коммуникационного канала курьеров. T3. Появление аналогичных решений у конкурентов: при запоздалом запуске преимущество «первого пользователя» утрачивается. T4. Деграция качества облачных LLM-сервисов вследствие изменения тарифов или условий использования.

Выводы по SWOT-анализу. Проект технически реализуем при текущих ресурсах компании (S1–S4 покрывают базовые требования к источникам данных и инфраструктуре), а внешняя среда поддерживает запуск (O1–O4). Главные риски — отсутствие in-house ML-экспертизы (W1) и регуляторные ограничения по обработке персональных данных (T1) — митигируются выбором self-hosted архитектуры на open-source моделях с возможностью замены LLM-модуля без переработки конвейера. Синтез возможностей и угроз с сильными и слабыми сторонами проводится в Разделе 1.7 настоящей главы (стратегические альтернативы и TOWS-анализ).

1.4. Анализ текущего процесса (AS-IS)

Для формализации текущего состояния процесса анализа обратной связи была построена модель бизнес-процесса в нотации BPMN 2.0 (Business

Process Model and Notation). Модель AS-IS отражает последовательность действий, выполняемых различными участниками процесса при обработке клиентской обратной связи в текущем режиме работы компании.

Процесс инициируется по расписанию: раз в неделю аналитик данных (DWH) выгружает клиентские отзывы из системы управления заказами (OMS) за отчётный период. Выгрузка включает оценку клиента по шкале от 1 до 5, а также текстовый комментарий, который является необязательным полем — значительная часть клиентов ограничивается только числовой оценкой. Внутренние коммуникации курьеров (Telegram-чаты) при этом не анализируются вовсе, поскольку отсутствует инструмент для их систематического сбора и обработки.

На втором этапе операционный аналитик пишет скрипт для обработки выгруженных данных и загружает результаты на корпоративный дашборд. Дашборд автоматически отображает агрегированные метрики: графики распределения оценок по времени, среднее значение рейтинга, количество отзывов по категориям. Однако визуализация ограничивается числовыми показателями и не включает анализ текстовых комментариев.

На третьем этапе менеджер просматривает дашборд и пытается извлечь инсайты из текстовых комментариев методом поиска по ключевым словам. Данный подход является принципиально ограниченным: ключевые слова не улавливают контекст, сарказм, синонимичные формулировки и неявно выраженные проблемы. Менеджер формирует выводы на основе субъективной интерпретации обнаруженных фрагментов и передаёт их руководителю.

На заключительном этапе руководитель получает аналитическую сводку с задержкой в 1–2 рабочих дня после завершения отчётного периода. Решения принимаются на основе неполных данных, обработанных через цепочку субъективных интерпретаций. Оперативное реагирование на выявленные проблемы оказывается затруднительным.




Рисунок 2. Модель бизнес-процесса анализа обратной связи AS-IS (BPMN 2.0)

Анализ модели BPMN AS-IS (Рисунок 2) позволяет выявить следующие ключевые проблемы текущего процесса:

- **Ограниченность поиска по ключевым словам** — менеджер не может выявить проблемы, сформулированные клиентами иначе, чем заданные ключевые слова. Сарказм, неявные жалобы и контекстно-зависимые формулировки остаются невидимыми.
- **Неполный охват источников** — внутренние коммуникации курьеров в Telegram-чатах полностью исключены из анализа, несмотря на их потенциальную ценность для раннего обнаружения операционных проблем.
- **Разрыв между числовыми и текстовыми данными** — дашборд эффективно визуализирует числовые оценки, но не способен объяснить причины низких оценок. Текстовые комментарии, содержащие ответ на вопрос «почему», остаются без систематического анализа.
- **Субъективность интерпретации** — выводы менеджера зависят от личного опыта, выбранных ключевых слов и количества времени, затраченного на просмотр. Два менеджера, анализирующие один массив данных, приходят к различным выводам.

– **Запаздывание отчётности** — задержка в 1–2 дня между сбором данных и доставкой выводов руководству делает реактивный характер управления неизбежным.

Для систематизации выявленных проблем и определения их корневых причин был проведён анализ с использованием диаграммы Исикавы (причинно-следственной диаграммы). Результаты анализа представлены на Рисунке 3.




Рисунок 3. Диаграмма Исикавы: корневые причины неэффективного анализа обратной связи

Диаграмма Исикавы (Рисунок 3) структурирует корневые причины неэффективности по пяти категориям:

- **Персонал (People):** зависимость выводов от субъективного восприятия конкретного менеджера; потеря накопленного контекстного знания при текучести кадров; невоспроизводимость аналитических результатов.
- **Процесс (Process):** отсутствие стандартизированной методологии анализа текстовых данных; исключение внутренних коммуникаций курьеров из периметра анализа; линейная цепочка передачи информации без обратной связи.

- **Технологии (Technology):** отсутствие инструмента автоматической обработки неструктурированного текста (NLP/LLM); дашборд ограничен визуализацией числовых показателей; поиск по ключевым словам как единственный метод работы с текстом.
- **Данные (Data):** объём текстовых комментариев превышает возможности ручного просмотра; мультиисточниковость данных (отзывы + чаты) при отсутствии единого конвейера обработки; неструктурированный характер текстовых данных.
- **Время (Time):** задержка 1–2 дня между сбором данных и формированием выводов; реактивный вместо проактивного характер аналитики; отчёты устаревают к моменту принятия решений.

Таким образом, совокупность выявленных проблем указывает на принципиальную ограниченность текущего подхода, основанного на ключевых словах, и необходимость внедрения методов семантического анализа текста, способных выявлять скрытые паттерны, обобщать формулировки и генерировать аналитические инсайты.

1.5. Обзор подходов к автоматизации анализа текстовых данных

Задача автоматизированного анализа текстовых данных прошла несколько этапов эволюции: от статистических методов извлечения признаков до современных генеративных моделей, способных не только классифицировать текст, но и формировать аналитические выводы на естественном языке. В настоящем разделе рассматриваются три поколения подходов применительно к задаче анализа клиентской обратной связи.

Статистические методы машинного обучения основаны на представлении текста в виде числового вектора признаков с последующим применением классификатора. Наиболее распространённой схемой векторизации является TF-IDF (Term Frequency – Inverse Document Frequency), которая присваивает каждому слову вес, отражающий его значимость в конкретном документе относительно всего корпуса. Полученные векторы подаются на вход классическим алгоритмам: логистической регрессии, методу опорных векторов (SVM), градиентному бустингу (XGBoost) или случайному лесу (Random Forest).

Преимущества данного подхода включают высокую скорость обработки, интерпретируемость результатов и низкие требования к вычислительным ресурсам. Однако модель «мешка слов» («мешок слов»), лежащая в основе TF-IDF, игнорирует порядок слов и синтаксические связи. Это приводит к неспособности улавливать контекст, обрабатывать отрицания («не плохо» интерпретируется как негативное из-за слова «плохо»), распознавать сарказм и учитывать богатую морфологию русского языка, где одно слово может иметь десятки словоформ.

Второе поколение подходов связано с парадигмой трансферного обучения (transfer learning) и архитектурой Transformer. Модель BERT (Bidirectional Encoder Representations from Transformers), предложенная Google в 2018 году, обучается на больших корпусах текста без учителя, формируя глубокое понимание языковых закономерностей. Для русского

языка существует адаптация RuBERT, обученная на корпусе русскоязычных текстов.

Применение BERT/RuBERT к задаче анализа тональности предполагает дообучение (fine-tuning) предварительно обученной модели на размеченном датасете отзывов. Данный подход обеспечивает существенный прирост качества по сравнению с TF-IDF благодаря учёту контекста, порядка слов и семантических связей. Вместе с тем, подход имеет ограничения, критичные для задачи настоящего проекта:

- необходимость размеченного обучающего датасета (сотни или тысячи вручную аннотированных примеров), которого у компании нет;
- одна модель решает одну задачу: для классификации тональности, категоризации тем и суммаризации требуются отдельные модели;
- модель возвращает метку класса (позитивный/негативный/нейтральный), но не объясняет, почему отзыв негативный, и не генерирует рекомендации по устранению проблемы.

Третье поколение представлено большими языковыми моделями (Large Language Models, LLM), которые ознаменовали переход от дискриминативной парадигмы (классификация) к генеративной (порождение текста). Ключевое отличие LLM от предыдущих подходов заключается в способности работать в режиме zero-shot и few-shot: модель выполняет задачу на основе текстовой инструкции (промпта) без необходимости дообучения на размеченных данных.

Для анализа обратной связи это означает принципиальное расширение возможностей. Единая модель способна в рамках одного запроса выполнить комплексный анализ: определить тональность, выделить тематику, обобщить ключевые проблемы и сформулировать гипотезу о корневой причине. Например, вместо метки «негативный» модель может выдать: «55% негативных отзывов за последнюю неделю связаны с повреждением упаковки при доставке — рекомендуется проверить стандарты упаковки на складе». Именно эта способность генерировать аналитические инсайты, а не

просто классифицировать тональность, делает LLM оптимальным инструментом для решения задачи настоящего проекта.

Для обработки больших объёмов данных, превышающих контекстное окно модели, применяется паттерн MapReduce: массив отзывов разбивается на пакеты (map-фаза), каждый пакет анализируется отдельно, затем промежуточные результаты синтезируются в итоговый отчёт (reduce-фаза). Автоматический подбор размера пакета (автоматическое пакетирование) обеспечивает адаптацию к различным ограничениям контекстного окна у разных моделей.

В рамках настоящего проекта рассматриваются несколько LLM-моделей и традиционный метод в качестве базовой линии (baseline). Для на собственной инфраструктуре развёртывания рассматриваются модели с открытыми весами; облачные модели (GPT, YandexGPT) описаны как альтернативы, однако не тестировались в эксперименте в связи с бюджетными ограничениями и требованиями информационной безопасности:

- **DeepSeek** (семейство моделей) — open-source модели с открытыми весами, допускающие развёртывание на собственной инфраструктуре; демонстрируют высокое качество работы с мультязычным текстом. Для эксперимента использована версия DeepSeek R1 7B через Ollama.
- **Qwen 2.5** — модель от Alibaba Cloud с открытой лицензией, поддерживающая на собственной инфраструктуре развёртывание; оптимизирована для аналитических задач.
- **GPT (OpenAI)** — семейство облачных моделей (GPT-3.5 Turbo, GPT-4o и более новые версии), доступных через платный API. Обеспечивают высокое качество, однако требуют передачи данных на внешние серверы и несут операционные затраты. В эксперименте не тестировались в связи с бюджетными ограничениями и требованиями информационной безопасности.

- **YandexGPT** — российская модель от Яндекса, изначально обученная на русскоязычных данных; доступна через API с хранением данных на территории РФ. В эксперименте не тестировалась в связи с бюджетными ограничениями API.
- **TF-IDF + XGBoost** — традиционный статистический метод, используемый как нижняя базовая линия для оценки прироста качества при переходе к LLM.
- **Fine-tuned RuBERT** — дообученный трансформер, используемый как промежуточная базовая линия, демонстрирующая возможности контекстных моделей без генеративных способностей.

Сравнительный анализ подходов позволяет выделить три ключевых критерия, по которым LLM-подход превосходит альтернативы в контексте задачи настоящего проекта. Во-первых, отсутствие потребности в размеченных данных: компания не располагает аннотированным корпусом отзывов, а создание такого корпуса потребовало бы значительных временных и трудовых затрат. Во-вторых, мультизадачность: единая модель заменяет конвейер из нескольких специализированных моделей (классификатор тональности + категоризатор тем + модель суммаризации). В-третьих, генерация инсайтов — способность не просто присвоить метку, а сформулировать аналитический вывод с рекомендацией, что радикально повышает ценность системы для лица, принимающего решения.

1.6. Требования к информационной безопасности при использовании LLM

При внедрении LLM для разбора отзывов и курьерских чатов возникает несколько рисков информационной безопасности. На них стоит обратить внимание ещё на этапе проектирования, а не доводить решение и потом перестраивать его под требования регуляторов.

В отзывах часто всплывают персональные данные — имя клиента, адрес доставки, номер заказа. В Telegram-чатах курьеров видны и операционные подробности: маршруты, складские операции, внутренние процессы компании. Если отправить такую информацию во внешние облачные API (OpenAI, Anthropic), эти данные физически уходят за периметр компании. Это прямой риск утечки. К тому же по 152-ФЗ персональные данные граждан РФ должны обрабатываться на серверах внутри страны, под что облачные сервисы крупных западных провайдеров просто не подходят.

Федеральный закон № 152-ФЗ «О персональных данных» устанавливает требования к обработке и хранению персональных данных граждан Российской Федерации на территории страны. Использование облачных API зарубежных провайдеров может создавать риски несоответствия данным требованиям, что делает вопрос архитектуры развёртывания модели юридически значимым.

Решением является использование моделей с открытыми весами (open-weight), допускающих развёртывание на собственной инфраструктуре компании (на собственной инфраструктуре deployment). Модели DeepSeek и Qwen 2.5 удовлетворяют данному требованию: их веса находятся в открытом доступе и могут быть развёрнуты на серверах с GPU внутри корпоративной сети. При таком подходе данные не покидают периметр компании, что устраняет риски утечки и обеспечивает соответствие регуляторным требованиям.

Вместе с тем, на собственной инфраструктуре развёртывание предполагает компромисс между безопасностью и производительностью.

Облачные модели (GPT-4o, Claude, Gemini) могут демонстрировать более высокое качество ответов, однако невозможность гарантировать безопасность данных делает их применение в продуктивной среде нецелесообразным. В рамках сравнительного эксперимента (Глава 3) облачная модель GPT-3.5 Turbo используется в качестве эталона качества на анонимизированных данных, тогда как продуктивная система будет построена на собственной инфраструктуре модели.

1.7. Стратегические альтернативы и обоснование выбора

SWOT-анализ из Раздела 1.3 даёт картину «что есть», но не отвечает на вопрос «что с этим делать». Здесь и нужен следующий шаг — TOWS-матрица. Она устроена как набор подсказок: на каждое пересечение внутренних факторов (сильные/слабые) с внешними (возможности/угрозы) предлагает конкретное стратегическое действие. Квадранты названы по комбинации: SO — как сильные стороны использовать на возможностях; ST — как сильными сторонами закрыть угрозы; WO — как через возможности нивелировать слабости; WT — оборонительный сценарий минимизации рисков. Сама матрица TOWS [57] показана в Таблице 1.3.

Для перехода от диагностического анализа к выбору стратегии применена матрица TOWS (Threats-Opportunities-Weaknesses-Strengths) — расширение SWOT, формирующее четыре стратегических квадранта на основе перекрёстного сопоставления внутренних и внешних факторов [57]. Результаты сведены в Таблице 1.3.

Таблица 1.3. Полиментная матрица (TOWS-анализ)

	Возможности (О)	Угрозы (Т)
Сильные стороны (S)	SO-стратегия (макси-макси). Использовать накопленную базу OMS-отзывов и Telegram-каналы (S1, S2) для быстрого запуска пилота на open-source LLM (O1), используя имеющиеся GPU-серверы (S3). Получить статус референс-кейса в e-commerce логистике (O4).	ST-стратегия (макси-мини). Self-hosted развёртывание LLM на корпоративной GPU-инфраструктуре (S3) полностью устраняет угрозу Т1 (ФЗ-152). Кросс-функциональная команда (S4) обеспечивает запуск в течение 4–6 месяцев, опережая возможный выход аналогичных решений у конкурентов (Т3).
Слабые стороны (W)	WO-стратегия (мини-макси). Использовать готовые open-source LLM (O1) для компенсации отсутствия ML-экспертизы (W1). Применение государственной грантовой поддержки (O2) для финансирования обучения команды по работе с LLM-инструментами.	WT-стратегия (мини-мини). Запустить пилот на ограниченной выборке (500 отзывов) с использованием существующих инструментов и модель-агностичного конвейера (паттерн MapReduce) для снижения рисков W1+T4. Архитектура обеспечивает безболезненную замену LLM-модели при ухудшении качества.

По таблице видно, что доминирует SO-стратегия. У компании уже есть GPU-инфраструктура и команда BI/IT (факторы S3, S4 из SWOT), а на внешнем рынке параллельно «созрели» открытые модели уровня Qwen 2.5 и DeepSeek (фактор O1). Логика отсюда простая — запускать проект быстро на self-hosted LLM, не ввязываясь в долгие согласования по закупке внешнего SaaS. WT-стратегия задаёт защитный контур: пилот на ограниченной

выборке с архитектурой, не привязанной к конкретной модели, чтобы при ухудшении конъюнктуры быстро переключиться.

На основе проведённого PEST- и SWOT-анализа сформированы три стратегические альтернативы решения выявленной проблемы — от пассивной до активной интервенции в существующий процесс.

Альтернатива 1 — «Статус-кво» (отказ от внедрения). Сохранение текущего ручного процесса обработки отзывов аналитиками с использованием Excel и поиска по ключевым словам. Прямые затраты отсутствуют; скрытые издержки выражаются в упущенных клиентских инсайтах, реактивном режиме работы с жалобами и удержании клиентов ниже потенциального уровня. Стратегический эффект — нарастающее технологическое отставание от конкурентов.

Альтернатива 2 — «Закупка SaaS-сервиса» (внешнее решение). Подключение к коммерческому облачному сервису анализа обратной связи (на российском рынке — Brand24, Glowbyte, Sherpa). Преимущества: быстрый запуск (1–2 месяца), готовый функционал, не требуется внутренняя экспертиза. Недостатки: ежемесячные платежи (от 1,2 млн руб. в год при текущем объёме отзывов), облачная обработка персональных данных с риском нарушения ФЗ-152, шаблонные категории тем без адаптации к домену e-commerce логистики, вендор-зависимость.

Альтернатива 3 — «Self-hosted LLM-конвейер собственной разработки» (выбранная стратегия). Разработка in-house информационно-аналитической системы на базе open-source LLM (Qwen, DeepSeek) с подключением отечественного YandexGPT в качестве резервного контура. Преимущества: полное соответствие ФЗ-152 (данные не покидают периметр), кастомизация под предметную область, развитие собственной ML-экспертизы как побочный эффект, отсутствие per-message-платежей, контроль над качеством через сравнительные эксперименты. Недостатки:

больший срок до запуска (4–6 месяцев), потребность в GPU-инфраструктуре, необходимость технической поддержки силами внутренней команды.

Таблица 1.4. Сравнение стратегических альтернатив по критериям

Критерий	Альт. 1 (статус-кво)	Альт. 2 (SaaS)	Альт. 3 (self-hosted)
Время до запуска	—	1–2 мес.	4–6 мес.
Прямые затраты, год 1	0 руб.	1,2–2,4 млн руб. + per-message	1,6–2,0 млн руб. (CAPEX + OPEX)
Соответствие ФЗ-152	не применимо	облачная обработка ПД (риск)	полное (on-premise)
Адаптация к домену	—	ограниченная (шаблоны)	полная (кастомные промпты)
Контроль качества	низкий	через метрики вендора	полный (сравнительные эксперименты)
Развитие in-house компетенций	нет	минимальное	значительное
Стратегический эффект	технологическое отставание	зависимость от вендора	развитие экспертизы + референс-кейс

Выбор Альтернативы 3 обоснован результатами PEST- и SWOT-анализа: сочетание благоприятной технологической среды (доступность open-source LLM), государственной поддержки импортозамещения и наличия внутренних ресурсов (OMS, Telegram-каналы, GPU-инфраструктура, кросс-функциональная команда) формирует оптимальный baseline для self-hosted решения. Регуляторные риски ФЗ-152 при таком подходе полностью митигируются, в отличие от SaaS-сценария. Дополнительный стратегический эффект — развитие in-house ML-экспертизы — создаёт устойчивое конкурентное преимущество, недостижимое при использовании внешних

сервисов. Указанная стратегическая альтернатива становится техническим заданием для Главы 2 настоящей работы, где формализуются функциональные и нефункциональные требования к системе.

1.8. Выводы по Главе 1

В первой главе проведён комплексный анализ текущего состояния процесса анализа обратной связи в логистической e-commerce компании. Основные результаты могут быть систематизированы следующим образом.

Анализ организационной модели (ArchiMate Organization View) выявил фрагментированность аналитического процесса: четыре подразделения компании работают с обратной связью изолированно, без единой аналитической платформы, что приводит к дублированию усилий и противоречивым выводам.

Модель бизнес-процесса AS-IS (BPMN 2.0) формализовала текущую последовательность действий и выявила ключевое узкое место: менеджер вынужден искать инсайты в текстовых комментариях методом ключевых слов, который принципиально неспособен обеспечить полноту и объективность анализа. Telegram-чаты курьеров полностью исключены из периметра аналитики.

Диаграмма Исикавы систематизировала корневые причины неэффективности по пяти категориям (персонал, процесс, технологии, данные, время), подтвердив, что проблема носит системный характер и требует комплексного технологического решения.

Обзор подходов к автоматизации анализа текстовых данных продемонстрировал, что большие языковые модели (LLM) обладают уникальным сочетанием свойств, необходимых для решения поставленной задачи: работа без размеченных данных, мультизадачность и способность генерировать аналитические инсайты. Анализ требований информационной

безопасности определил необходимость на собственной инфраструктуре развёртывания модели.

Выявленные проблемы и их корневые причины формируют обоснование для разработки автоматизированной информационно-аналитической системы. В Главе 2 каждая из идентифицированных корневых причин будет трансформирована в конкретное функциональное или нефункциональное требование к целевой системе, на основе которых будет спроектирована архитектура решения.

Глава 2. Проектирование информационно-аналитической системы

2.1. Формирование требований к системе

На основании результатов анализа, проведённого в Главе 1, сформулированы функциональные и нефункциональные требования к информационно-аналитической системе. Каждое требование прослеживается до конкретной корневой причины, выявленной при анализе диаграммы Исикавы и модели BPMN AS-IS.

Каждое требование сформулировано отдельно и проверяемо: одно требование описывает один наблюдаемый эффект системы. За основу взят шаблон Volere (Robertson, 2012). Для каждого требования есть ссылка на конкретную проблему из Главы 1 — это даёт прослеживаемость от анализа AS-IS до итоговой спецификации.

Функциональные требования описывают, что система делает.

- **FR-1. Автоматический сбор данных из OMS:** система должна автоматически извлекать клиентские отзывы и оценки из системы управления заказами по расписанию или по триггеру, исключая ручную выгрузку аналитиком DWH.
- **FR-2. Автоматический сбор сообщений из Telegram:** система должна собирать и обрабатывать сообщения из Telegram-чатов курьеров через Bot API, расширяя периметр анализа за пределы клиентских отзывов.
- **FR-3. Автоматическая классификация тональности:** система должна определять тональность каждого текстового сообщения (позитивная, негативная, нейтральная) с использованием LLM без необходимости предварительной разметки данных.
- **FR-4. Автоматическое выделение тематик:** система должна категоризировать обратную связь по тематическим кластерам

(доставка, упаковка, интерфейс, качество товара и др.) на основе семантического анализа, а не ключевых слов.

– **FR-5. Генерация аналитических инсайтов:** система должна формировать текстовые аналитические выводы с рекомендациями, агрегируя результаты анализа отдельных сообщений в итоговый отчёт (паттерн MapReduce).

– **FR-6. Интерактивная визуализация:** система должна предоставлять интерактивный дашборд с возможностью детализированный анализ анализа, фильтрации по периодам, источникам и тематикам, заменяя статичные Excel-отчёты.

– **FR-7. Автоматические уведомления:** система должна отправлять алерты при обнаружении критических изменений (резкое ухудшение тональности, аномальный рост негативных отзывов по определённой теме).

– **FR-8. Поддержка нескольких LLM-моделей:** система должна поддерживать подключение различных LLM (DeepSeek, Qwen и другие модели с открытыми весами, а также облачные API при необходимости) для проведения сравнительного эксперимента и выбора оптимальной модели.

Нефункциональные требования определяют ограничения и качественные характеристики системы:

– **NFR-1. Информационная безопасность:** данные клиентов и внутренние коммуникации курьеров не должны покидать периметр корпоративной сети. Продуктивная модель LLM должна быть развёрнута на собственной инфраструктуре (на собственной инфраструктуре).

– **NFR-2. Производительность:** полный цикл анализа (сбор – обработка – визуализация) должен завершаться в течение минут, а не дней, обеспечивая переход от реактивной к проактивной аналитике.

- **NFR-3. Масштабируемость:** механизм автоматическое пакетирование должен обеспечивать адаптацию к росту объёма обратной связи без деградации качества и времени обработки.
- **NFR-4. Расширяемость:** архитектура системы должна допускать подключение новых источников данных и новых LLM-моделей без существенной переработки кода.

Таблица трассировки показывает связь между корневыми причинами (Рисунок 3) и требованиями: категория «Технологии» покрывается требованиями FR-3, FR-4, FR-5, FR-8; категория «Процесс» — требованиями FR-1, FR-2; категория «Данные» — FR-2, NFR-3; категория «Время» — FR-7, NFR-2; категория «Персонал» — FR-3, FR-4 (устранение субъективности за счёт автоматизации).

2.2. Проектирование архитектуры системы

Архитектура информационно-аналитической системы спроектирована на основе принципа разделения ответственности (separation of concerns) и включает четыре логических слоя: сбор данных, хранение, обработка и представление. Каждый слой реализован как независимый набор компонентов, взаимодействующих через определённые интерфейсы.

Для визуализации архитектуры использованы две взаимодополняющие нотации: ArchiMate (Business Cooperation View) — для отображения целевого состояния бизнес-кооперации с точки зрения способностей, процессов и сервисов, и C4 Model [16] — для детализации технической архитектуры на уровне контекста и контейнеров.




Рисунок 4. Модель бизнес-кооперации TO-BE (ArchiMate Business Cooperation View)

Диаграмма бизнес-кооперации TO-BE (Рисунок 4) показывает целевое состояние после внедрения ИАС. Те же три способности (Capability) теперь реализуются полноценно: бизнес-процессы автоматизированного конвейера (сбор обратной связи — препроцессинг и батчинг — LLM-анализ в фазе Map — агрегация в фазе Reduce — формирование аналитического отчёта — эскалация критических сигналов) обеспечивают новые бизнес-сервисы (сервис аналитики тональности, выявление топ-проблем, рекомендации по улучшению, алертинг), которые потребляются теми же бизнес-акторами — менеджером по качеству, руководителем логистики и продуктовой командой. Сравнение с диаграммой AS-IS (Рисунок 1) показывает реинжиниринг бизнес-кооперации: ручные процессы заменены автоматизированными, реактивная реакция на жалобы — проактивным алертингом, а способность «Раннее выявление операционных инцидентов» из непокрытой становится полноценно реализованной. Техническая реализация компонентов системы (контейнеры, технологический стек, протоколы взаимодействия) подробно раскрыта в C4 Context и C4 Container диаграммах далее (Рисунки 5, 6).

На Рисунке 6 показаны и те компоненты, которые в рамках ВКР доведены только до уровня проектных решений — REST API, email-уведомления, выделенный Data Lake (PostgreSQL + MinIO), коннектор к промышленной OMS. Их полноценная разработка вынесена в раздел «Направления дальнейшей работы» в Заключение. Такое разделение типично для проектной ВКР: архитектура показывает, что решение продумано целиком, а реализованный фрагмент даёт возможность проверить ключевые гипотезы и прогнать сравнительный эксперимент на репрезентативной выборке.

В центре системы — LLM-конвейер из трёх фаз. Сначала препроцессор чистит тексты и разбивает их на пакеты подходящего размера (auto-batching). Далее LLM Engine разбирает каждый пакет (фаза Map). На финале агрегатор собирает промежуточные результаты в один итоговый отчёт (фаза

Reduce). Готовый результат уходит в аналитическую базу, откуда его можно получить тремя путями — открыть дашборд, дёрнуть REST API из другой системы или получить пуш-уведомление о критическом сигнале.




Рисунок 5. C4 Context Diagram

На Контекстной диаграмме C4 (Рисунок 5) система показана как один блок, вокруг которого расположены внешние участники.




Рисунок 6. C4 Container Diagram

Контейнерная диаграмма C4 (Рисунок 6) детализирует внутреннюю структуру системы до уровня развёртываемых компонентов. Система включает девять контейнеров, реализованных преимущественно на языке Python с использованием фреймворка FastAPI для сервисной логики и Streamlit для визуализации. LLM Model Server реализован на базе vLLM или Ollama, обеспечивающих эффективное обслуживание моделей с открытыми весами на GPU-серверах.




Рисунок 7. C4 Component Diagram: внутренняя структура контейнера LLM Pipeline

Component-диаграмма третьего уровня модели C4 (Рисунок 7) детализирует контейнер LLM Pipeline до уровня внутренних программных компонентов. Контейнер реализован как единое FastAPI-приложение и декомпозируется на семь функциональных компонентов: API Endpoint (REST-интерфейс), Data Loader (выгрузка сырых данных из Data Lake), Preprocessor (очистка и нормализация текста), Auto-Batcher (формирование пакетов по размеру контекстного окна модели), Map Worker (Map-фаза с вызовом LLM), Reducer (Reduce-фаза агрегации результатов), Result Writer (запись итогового отчёта в Аналитическую БД). Внешние взаимодействия — с Data Lake, LLM Model Server и Аналитической БД — обозначены стрелками, выходящими за пределы контейнера. Двухнаправленная связь

между Map Worker и LLM Model Server отражает синхронный характер запросов к LLM.

Выбор технологического стека обусловлен следующими соображениями. Python является стандартом де-факто для задач машинного обучения и обработки естественного языка, обеспечивая доступ к экосистеме библиотек (transformers, langchain, vllm). FastAPI обеспечивает асинхронную обработку запросов, критичную для взаимодействия с LLM. PostgreSQL выбран в качестве основного хранилища благодаря поддержке JSONB для хранения полуструктурированных результатов анализа и полнотекстового поиска для русского языка. MinIO используется для хранения сырых текстовых данных в формате объектного хранилища, обеспечивая масштабируемость при росте объёмов.

Сводная характеристика компонентов технологического стека с указанием конкретных технологий и обоснований выбора представлена в Таблице 2.5.

Таблица 2.5

Технологический стек системы

Компонент	Технология	Обоснование выбора
Язык программирования	Python 3.10+	Стандарт де-факто для задач ML/NLP; экосистема библиотек transformers, langchain, vllm
API-слой	FastAPI	Асинхронная обработка запросов, критичная для взаимодействия с LLM
Self-hosted LLM	Ollama (среда разработки) — vLLM (продуктовый контур)	Ollama — простое развёртывание на single-GPU; vLLM с PagedAttention обеспечивает высокую пропускную способность в проде
Облачный LLM	YandexGPT Pro / Embeddings (Yandex Cloud SDK)	Российская юрисдикция данных, соответствие требованиям 152-ФЗ
Реляционная СУБД	PostgreSQL	JSONB для полуструктурированных результатов анализа, полнотекстовый поиск для русского языка

Компонент	Технология	Обоснование выбора
Объектное хранилище	MinIO	S3-совместимое масштабируемое хранилище для сырых текстовых данных
Аналитический дашборд	Streamlit + Plotly	Быстрое прототипирование интерактивного UI поверх pandas-датафреймов без frontend-разработки
Telegram-бот	aiogram 3	Асинхронная библиотека Python, поддержка актуальной версии Telegram Bot API
Baseline-классификатор	TF-IDF + XGBoost (scikit-learn, xgboost)	Индустриальный стандарт калиброванного бейзлайна для классификации текстов
LLM-модели эксперимента	Qwen 2.5 7B, DeepSeek LLM/R1 7B, YandexGPT Pro/Embeddings/Classifier	Семь моделей для сравнительной оценки в Главе 3.3

Дополнительно следует отметить два аспекта выбора стека, выходящих за рамки сводной таблицы. Во-первых, миграция self-hosted развёртывания LLM с Ollama (использовалось в среде разработки) на vLLM в продуктивном контуре обусловлена существенно более высокой пропускной способностью последнего за счёт механизма PagedAttention и эффективного батчинга запросов. Во-вторых, обоснование выбора конкретных LLM-моделей (Qwen 2.5, DeepSeek, YandexGPT) с учётом ограничений по памяти GPU, требований к латентности и поддержке русского языка приведено в Разделе 3.2.

Используемая в работе совокупность диаграмм образует многопроекционную модель архитектуры, соответствующую сложившимся практикам описания архитектуры программных систем: одна и та же система описывается с разных точек зрения для разных групп стейкхолдеров. ArchiMate Business Cooperation (Рисунки 1, 4) представляет бизнес-уровень для руководства, BPMN (Рисунки 2, 8) — операционно-процессный уровень для аналитиков, модель C4 (Рисунки 5, 6, 7) — технический уровень для

архитекторов, а UML Activity (Рисунок 9) и ER-диаграмма (Рисунок 10) — детальный уровень для разработчиков. Кажущееся дублирование информации между диаграммами является методически осознанным: каждая нотация подсвечивает свой аспект (структура взаимодействия, временной поток, технологический стек, потоки данных). Декомпозиция контейнера LLM Pipeline до уровня компонентов (третий уровень модели C4) представлена на Рисунке 7 ниже.

2.3. Модель целевого бизнес-процесса (ТО-BE)

На основе сформулированных требований и спроектированной архитектуры построена модель целевого бизнес-процесса в нотации BPMN 2.0. Модель ТО-BE отражает последовательность действий при анализе обратной связи после внедрения информационно-аналитической системы.




Рисунок 8. Модель бизнес-процесса работы менеджера с обратной связью ТО-BE (BPMN 2.0)

Сравнение моделей AS-IS (Рисунок 2) и ТО-BE (Рисунок 8) демонстрирует принципиальные изменения в структуре процесса. В результате реинжиниринга бизнес-процесса человеческая часть схлопывается до одного пула «Менеджер по качеству сервиса»: автоматическая аналитика (сбор данных, препроцессинг, LLM-анализ, агрегация и формирование

инсайтов) вынесена во внешний «чёрный ящик» — collapsed pool «ИАС», который взаимодействует с пулом менеджера через message flows (алерты и запросы дашборда). На стороне менеджера остаются только осмысленные действия с инсайтами: открытие дашборда, изучение топ-проблемы (drill-down), принятие решения через exclusive gateway «Требуется действие?», постановка задачи команде в Tracker и уведомление ответственного. Параллельно поддерживается плановая ветка (timer event «Понедельник 09:00») — формирование рекомендаций продуктовой команде по недельным трендам.

Если коротко суммировать, в чём TO-BE-процесс выигрывает у AS-IS, получается пять пунктов:

- Охват. В анализ теперь попадают и Telegram-чаты курьеров — до этого их никто не разбирал. Два коннектора (OMS и Telegram-бот) работают одновременно, поэтому видна полная картина, а не только клиентская сторона.
- Семантический разбор вместо поиска по словам. LLM видит контекст, сарказм, перефразирование — это особенно важно для русских отзывов, где одну и ту же претензию люди формулируют десятком способов.
- Готовые инсайты вместо догадок. Модель сразу формирует структурированный отчёт с конкретными рекомендациями. Два разных запуска на одной выборке дают один и тот же результат — чего ручной разбор не давал.
- Время. Цикл сократился с 1–2 рабочих дней до минут. По сути, аналитика переезжает из реактивной (разбираемся постфактум) в проактивную (видим проблему сразу).
- **Устранение межфункциональных зависимостей:** автоматизация сбора и обработки данных устраняет зависимость от аналитика DWH и операционного аналитика, снижая риски, связанные с текучестью кадров.

- **Проактивные уведомления:** система автоматически генерирует алерты при обнаружении критических изменений, не дожидаясь запроса от руководителя.

Таким образом, модель ТО-ВЕ демонстрирует, что внедрение информационно-аналитической системы на основе LLM устраняет все пять категорий корневых причин, выявленных в диаграмме Исикавы (Рисунок 3): субъективность персонала заменяется алгоритмической обработкой; процесс стандартизируется и расширяется; технологический разрыв закрывается внедрением LLM; данные из нескольких источников обрабатываются единым конвейером; временные задержки сокращаются до минут.

2.4. Проектирование алгоритма обработки данных

Детализация алгоритмической логики обработки данных в LLM-конвейере представлена на диаграмме UML Activity, отражающей последовательность фаз обработки от приёма данных до сохранения результатов. Использование нотации UML Activity Diagram обусловлено её способностью одновременно описывать управляющий поток, точки решений, параллельную обработку и циклы — что точно соответствует структуре конвейера MapReduce с автоматическим пакетированием, разработанного в настоящей работе.

Общая логика работы конвейера представлена на диаграмме UML Activity (Рисунок 9). Процесс включает пять последовательных фаз: подготовка данных, автоматическое формирование пакетов (batching), параллельный анализ пакетов (фаза отображения (Map)), агрегация результатов (фаза свёртки (Reduce)) и доставка результатов пользователям.




Рисунок 9. UML Activity Diagram: конвейер обработки данных (MapReduce)

На фазе подготовки система извлекает сырые данные из Data Lake, выполняет очистку текста (удаление HTML-разметки, emoji, нормализация пробелов и пунктуации) и дедупликацию. Для данных из OMS и Telegram используются различные модули предобработки, учитывающие специфику каждого источника: отзывы клиентов проходят стандартную нормализацию, тогда как сообщения из Telegram дополнительно обрабатываются для удаления служебных сообщений бота, объединения коротких последовательных сообщений одного автора и фильтрации нерелевантного содержания.

Механизм автоматического пакетирования определяет оптимальный размер пакета на основе двух параметров: размера контекстного окна текущей модели и средней длины текста в обрабатываемом массиве. Размер пакета рассчитывается по формуле (1):

$$batch_size = \left\lfloor \frac{context_window \times fill_ratio}{avg_token_count} \right\rfloor \quad (1)$$

Здесь `context_window` — это размер контекстного окна модели в токенах, `fill_ratio` — какую долю окна можно занять (берём 0,7, остальное оставляем под системный промпт и место для ответа), `avg_token_count` — средняя длина одного отзыва в токенах, а `floor` округляет результат вниз до целого числа отзывов в пакете.

Подход адаптивный: модель с окном 32K (Qwen 2.5) сама получит пакеты заметно больше, чем GPT-3.5 Turbo с 16K. Никакой ручной донастройки под каждую модель не требуется.

На фазе Map каждый пакет уходит в LLM отдельным запросом. Системный промпт подбирается по `source_type`: для отзывов клиентов модель определяет тональность, темы и формулирует выводы, для курьерских сообщений — выявляет операционные инциденты и системные жалобы.

На фазе свёртки промежуточные результаты всех пакетов агрегируются: система формирует итоговый отчёт, включающий распределение тональности, ранжированный список проблем, тематические

тренды и текстовые рекомендации. При обнаружении критических изменений (резкий рост негативной тональности, появление новой массовой проблемы) система автоматически генерирует алерт.

2.5. Проектирование структуры хранилища данных

Для обеспечения хранения сырых данных, промежуточных результатов обработки и итоговых аналитических отчётов спроектирована реляционная структура хранилища. Выбор реляционной модели обусловлен необходимостью гарантии целостности данных, поддержки сложных запросов агрегации и совместимости с типовой корпоративной инфраструктурой (PostgreSQL как целевая СУБД). Концептуальная структура представлена в нотации «сущность-связь» (Entity-Relationship) [51].

Структура базы данных, обеспечивающая хранение сырых данных, промежуточных и итоговых результатов анализа, представлена на ER-диаграмме (Рисунок 10).




Рисунок 10. ER-диаграмма структуры базы данных ИАС

База данных включает восемь таблиц, организованных по принципу разделения сырых и обработанных данных. Таблицы raw_reviews и

raw_messages хранят исходные данные из OMS и Telegram соответственно, обеспечивая их раздельное хранение. Таблица batches фиксирует метаданные каждого пакета обработки. Таблица analysis_items содержит результаты анализа на уровне отдельных элементов с привязкой к исходному объекту через source_id и source_type. Поля типа JSONB (topics, key_phrases, top_problems) обеспечивают гибкость хранения полуструктурированных результатов LLM-анализа. Таблица models_config хранит конфигурации подключённых LLM-моделей, позволяя переключать активную модель без изменения кода.

2.6. Экономическое обоснование

Для обоснования целесообразности внедрения информационно-аналитической системы проведён расчёт ожидаемого экономического эффекта. Основным источником экономии является сокращение трудозатрат сотрудников, занятых в ручном процессе анализа обратной связи. Инфраструктурные расходы (GPU-сервер, электроэнергия, поддержка) рассматриваются как фиксированная составляющая ИТ-бюджета компании и не учитываются при расчёте чистой экономии.

В Таблице 2.1 представлен расчёт трудозатрат при текущем процессе анализа обратной связи. Часовые ставки сотрудников рассчитаны на основе среднерыночных заработных плат в российских e-commerce компаниях (2026 г.) с учётом налоговой нагрузки (страховые взносы 30%).

Роль	Ч/неделя	Ставка, руб/ч	Руб/нед	Руб/год (52 нед)
Аналитик данных (DWH)	2	1 200	2 400	124 800
Операционный аналитик	4	720	2 880	149 760
Менеджер клиент. опыта	10	840	8 400	436 800
Руководитель	2,5	1 500	3 750	195 000
ИТОГО	18,5	—	17 430	906 360

Таблица 2.1. Трудозатраты на анализ обратной связи (AS-IS)

После внедрения ИАС ручные этапы сбора и первичной обработки данных полностью автоматизируются. Менеджер переключается с поиска по ключевым словам на работу с готовыми аналитическими выводами, что радикально сокращает необходимое время. Роли аналитика данных и операционного аналитика высвобождаются для других задач. Расчёт приведён в Таблице 2.2.

Роль	Ч/неделя	Ставка, руб/ч	Руб/нед	Руб/год (52 нед)
Аналитик данных (DWH)	0	—	0	0
Операционный аналитик	0	—	0	0
Менеджер клиент. опыта	2	840	1 680	87 360
Руководитель	0,5	1 500	750	39 000
ИТОГО	2,5	—	2 430	126 360

Источник: [58]. Часовые ставки получены пересчётом медианного оклада брутто на стандартное рабочее время 172 ч/мес с учётом страховых взносов 30 % и представляют собой консервативную нижнюю оценку относительно медианного уровня рынка.

Таблица 2.2. Трудозатраты на анализ обратной связи (ТО-ВЕ)

Сравнение таблиц 4 и 5 показывает, что внедрение ИАС позволяет сократить суммарные трудозатраты команды, занятой анализом обратной связи, с 18,5 до 2,5 часов в неделю — в 7,4 раза. Годовая экономия на одной бизнес-команде составляет:

$$\Delta Z = 906\,360 - 126\,360 = 780\,000 \text{ руб/год}$$

Для крупной e-commerce компании, оперирующей несколькими направлениями обратной связи (клиентские отзывы, курьерские чаты, службы поддержки), масштабирование решения на 3–5 аналогичных команд даёт совокупную экономию порядка 2,3–3,9 млн рублей в год.

Дополнительные (немонетизированные) эффекты

Помимо прямой экономии трудозатрат, внедрение ИАС обеспечивает ряд эффектов, сложно поддающихся прямой денежной оценке, но имеющих значительное влияние на бизнес-показатели:

- **Сокращение времени реакции:** выявление критических проблем за минуты вместо 1–2 дней позволяет предотвращать отток клиентов на ранней стадии.

- **Расширение периметра анализа:** включение Telegram-чатов курьеров в анализ открывает доступ к операционным инсайтам, ранее недоступным руководству.
- **Повышение объективности решений:** устранение субъективности при ручном поиске по ключевым словам снижает риск неверных управленческих решений на основе неполной картины.
- **Масштабируемость:** система обрабатывает рост объёма обратной связи без пропорционального увеличения штата аналитиков.
- **Накопление базы инсайтов:** автоматически формируемая аналитическая БД становится корпоративным активом, доступным для ретроспективного анализа.

Замечание об инфраструктурных затратах

Инфраструктурные затраты на развёртывание ИАС включают: GPU-сервер (собственный либо арендованный в облаке Yandex Cloud), электроэнергию, лицензирование программного обеспечения (при необходимости) и сопровождение. Данные затраты относятся к общему ИТ-бюджету компании и не учитываются при расчёте чистой экономии, поскольку: (1) компания уже располагает серверной инфраструктурой как неотъемлемой частью операционной деятельности; (2) инкрементальные затраты на ИАС (один GPU-сервер среднего класса) многократно перекрываются объёмом высвобождаемых трудозатрат; (3) возможно использование облачных API (YandexGPT) с оплатой по факту потребления, что устраняет капитальные инвестиции.

Вывод

Проведённый расчёт показывает, что внедрение ИАС экономически целесообразно: годовая экономия на трудозатратах одной команды составляет около 780 тыс. руб, а масштабирование на несколько направлений обратной связи увеличивает эффект в 3–5 раз. С учётом немонетизированных

эффектов (скорость реакции, полнота анализа, объективность решений) совокупный бизнес-эффект от внедрения существенно превышает прямую экономию трудозатрат.

2.7. Управление рисками проекта

Успешная реализация проекта внедрения информационно-аналитической системы требует систематического управления рисками. На основании анализа специфики проекта (использование LLM-моделей, интеграция с внешними системами, работа с чувствительными данными) идентифицированы 12 ключевых рисков, сгруппированных по пяти категориям: технические, организационные, финансовые, регуляторные и связанные с качеством данных.

Каждый риск оценён по двум параметрам: вероятности возникновения и влиянию на проект. Матрица рисков, отражающая распределение идентифицированных рисков по этим параметрам, представлена на Рисунке 11.




Рисунок 11. Матрица рисков проекта внедрения ИАС

Детальное описание рисков, их оценка и меры митигации приведены в Таблице 2.3.

D	Описание	Вероятность	Влияние	Уровень	Меры митигации
1	Деградация качества LLM	Средняя	Высокое	Высокий	Настройка промптов, резервная модель
2	Низкая скорость GPU	Средняя	Среднее	Средний	Мониторинг, рост мощностей, автоскейлинг
3	Сбои облачного API	Высокая	Низкое	Средний	Локальная модель как резерв, повтор
4	Ошибки парсинга JSON	Высокая	Среднее	Высокий	Валидация схемы, автоповтор
5	Соппротивление персонала	Средняя	Высокое	Высокий	Обучение, быстрые победы, вовлечение
6	Нет экспертизы по промптам	Средняя	Среднее	Средний	Обучение, наём, консалтинг
7	Превышение бюджета на GPU	Низкая	Высокое	Средний	Резерв 15%, аренда на старте
8	Ужесточение 152-ФЗ	Низкая	Высокое	Средний	Локальная архитектура, аудит
9	Блокировка Telegram	Низкая	Среднее	Низкий	Модульный сбор, альтернативы
10	Утечка ПДн через облако	Низкая	Высокое	Средний	Маскирование, локальное хранение
11	Низкое качество данных	Средняя	Среднее	Средний	Валидация, фильтрация
12	Текучка кадров	Высокая	Низкое	Средний	Документация, парная работа, бонусы

Источник: расчёты автора; часовые ставки — по Таблице 2.1 [58]. Параметры остаточной нагрузки (2 ч/нед на интерпретацию результатов LLM, 0,5 ч/нед руководителя) получены по хронометражу на демонстрационном цикле.

Таблица 2.3. Реестр рисков проекта внедрения ИАС

Среди идентифицированных рисков особого внимания требуют риски высокого уровня (R1, R4, R5), а также риски, имеющие высокий потенциальный ущерб даже при низкой вероятности (R7, R8, R10).

Риск R1 (деградация качества LLM) критичен на этапе пилота и MVP: неудовлетворительное качество инсайтов может подорвать доверие пользователей на раннем этапе. Митигация: использование развёрнутой базы

тестовых данных, метрический контроль после каждого обновления промптов, возможность быстрого переключения между моделями (Qwen, DeepSeek, YandexGPT).

Риск R4 (ошибки парсинга JSON) проявляется регулярно: в эксперименте DeepSeek R1 выдала только 52% валидных парсов. Митигация: схемная валидация ответов, автоповтор с уточнением промпта, отказ от reasoning-моделей в пользу базовых LLM.

Риск R5 (сопротивление персонала) является типичным для ИТ-проектов и требует системной работы: менеджеры, привыкшие к ручному процессу, могут воспринимать автоматизацию как угрозу. Митигация: ранее вовлечение пользователей в настройку промптов, демонстрация конкретных быстрых побед (например, обнаружение новой операционной проблемы на неделю раньше), позиционирование системы как инструмента, а не замены.

Риск R10 (утечка ПДн) имеет низкую вероятность благодаря self-hosted архитектуре, но максимальное влияние: репутационные и регуляторные последствия могут быть критическими. Митигация: строгое разделение чувствительных и нечувствительных данных; облачные API используются только для обезличенных выборок.

Остаточные риски (после применения мер митигации) оцениваются как приемлемые для запуска проекта. Регулярный пересмотр реестра рисков предусмотрен на границах фаз проекта (контрольные точки, определённые в плане проекта).

2.8. Ключевые показатели эффективности

Для объективной оценки успешности внедрения ИАС определён набор ключевых показателей эффективности (KPI), охватывающих три уровня: бизнес-показатели, операционные показатели и технические показатели качества. Каждый показатель имеет целевое значение, способ измерения и периодичность контроля. Значения AS-IS получены на основании хронометража текущего процесса в компании, значения TO-BE —

прогнозные на основании результатов эксперимента (Глава 3) и аналогов из отрасли.

KPI	Метрика	AS-IS	TO-BE	Способ измерения
Бизнес-показатели				
Time to Insight	Время от сбора данных до инсайта	1–2 раб. дня	5–15 минут	Логи системы, отметки времени
Coverage	% проанализированной обратной связи	~20%	≥ 95%	Отношение обработанных к поступившим
Сокращение труда	Часов в неделю на анализ	18,5 ч/нед	2,5 ч/нед	Хронометраж менеджеров
Cost savings	Экономия ФОТ в год (1 команда)	—	≈ 780 тыс. руб	Расчёт по Таблицам 4–5
Actionability rate	% инсайтов, приведших к действиям	Не измерялось	≥ 40%	Связь «инсайт — тикет»
Time to Action	Время от обнаружения до решения	3–5 дней	< 1 дня	Интервал создание алерта — действие
Операционные показатели				
Uptime	Доступность ИАС	—	≥ 99,5%	Мониторинг Prometheus/Grafana
Throughput	Отзывов в минуту	—	≥ 50 отз./мин	Нагрузочное тестирование
Стоимость обработки	Руб. на 1 000 отзывов (YandexGPT Pro)	—	≈ 250 руб	Биллинг Yandex Cloud
Технические показатели качества				
Macro F1	Качество определения тональности	—	≥ 0,65	Проверка на размеченной выборке
Parse rate	% валидно распарсенных JSON-ответов	—	≥ 98%	Логи парсера
Expert rating	Оценка полезности инсайтов (1–5)	—	≥ 4,0	Квартальный опрос менеджеров

Таблица 2.4. Ключевые показатели эффективности ИАС

Бизнес-показатели отражают ценность системы с точки зрения руководства и собственников компании. Наиболее значимыми являются Time to Insight (сокращение с 1–2 дней до минут) и Coverage (рост охвата анализа с ~20% до ≥95%). Метрика Cost savings количественно подтверждает экономическую целесообразность проекта.

Uptime $\geq 99,5$ % — это стандарт для корпоративных аналитических систем; throughput от 50 отзывов в минуту позволяет прогнать недельный пакет (~3000 отзывов) за считанные минуты.

Технические метрики ловят деградацию модели. Падение Macro F1 ниже 0,60 или parse rate ниже 95 % — повод вернуться к промптам или сменить базовую модель.

Контроль KPI разнесён по частоте: бизнес-показатели смотрят раз в месяц, операционные — в реальном времени через мониторинг, технические — раз в неделю по автоматическому отчёту. Если что-то ушло от цели больше чем на 15 %, запускается разбор причин.

2.9. Выводы по Главе 2

Во второй главе спроектирована ИАС анализа обратной связи на базе LLM. Если коротко суммировать, что получилось:

Сформулированы восемь функциональных требований (FR-1 — FR-8) и четыре нефункциональных (NFR-1 — NFR-4). Каждое

Архитектура построена на классическом разделении ответственности — четыре слоя: сбор данных, хранение, обработка (LLM-конвейер с MapReduce) и представление. Для визуализации использованы ArchiMate и C4 Model на трёх уровнях детализации.

Модель TO-BE показывает, что внедрение системы закрывает все корневые причины из Исикавы. Охват данных расширяется, ключевые слова заменяются семантическим разбором, инсайты генерируются автоматически, цикл анализа сокращается, а субъективность аналитика уходит.

В Главе 3 будет представлена реализация спроектированной системы: описание конвейера обработки данных, результаты сравнительного эксперимента с пятью моделями (три LLM и два обученных baseline), а также анализ полученных результатов.

Глава 3. Реализация системы и экспериментальная оценка

3.1. Реализация конвейера обработки данных

Программная реализация информационно-аналитической системы выполнена на языке Python (версия 3.10+) с использованием следующего технологического стека: для self-hosted развёртывания LLM-моделей применяется Ollama (поддержка моделей DeepSeek, Qwen, Llama 3); облачный контур реализован через Yandex Cloud SDK для подключения YandexGPT; интерактивный дашборд построен на фреймворке Streamlit с использованием библиотеки визуализации Plotly; модуль сбора данных из Telegram-каналов курьеров реализован на фреймворке aiogram. Реализация механизма автоматического пакетирования по формуле (1), приведённой в Разделе 2.4, обеспечивает адаптацию системы к различным моделям без ручной настройки. GitHub. Скриншоты пользовательского интерфейса аналитического дашборда, отражающие основные функциональные возможности реализованной системы, приведены в Приложении Б.

3.2. Методика сравнительного эксперимента

Для выбора оптимальной LLM-модели для продуктивного развёртывания разработана методика сравнительного эксперимента, включающая семь моделей, набор метрик качества и единую процедуру оценки.

Эксперимент проводится на двух выборках данных. Первая выборка включает клиентские отзывы из OMS за репрезентативный период, содержащие как текстовые комментарии, так и числовые оценки (1–5), которые используются в качестве эталонная разметка для задачи классификации тональности. Вторая выборка включает сообщения из Telegram-чатов курьеров, размеченные экспертами по наличию операционных инцидентов.

В эксперименте сравниваются семь моделей:

– TF-IDF + XGBoost — обучаемый baseline на 89,5 тыс. размеченных примерах: векторизация TF-IDF с последующей классификацией градиентным бустингом. Используется как нижняя референтная точка для оценки прироста качества при переходе к LLM.

– YandexGPT Embeddings + LogReg — гибридный подход: облачные векторные представления YandexGPT (768-мерные эмбединги) с классификатором на основе логистической регрессии, обученным на 300 размеченных примерах.

– YandexGPT Pro — облачная генеративная LLM от Яндекса в режиме zero-shot. Контекстное окно 8 тыс. токенов, хранение данных на территории РФ через Yandex Cloud.

– YandexGPT Classifier — готовый облачный zero-shot-классификатор тональности от Яндекса. Включён в эксперимент для оценки применимости предобученных доменно-нейтральных классификаторов без дополнительной настройки.

– Qwen 2.5 7B — open-weight LLM от Alibaba Cloud, развёрнутая локально через Ollama в режиме zero-shot. Контекстное окно 32 тыс. токенов, поддержка русского языка.

– DeepSeek LLM 7B — open-weight базовая LLM, развёрнутая локально через Ollama в режиме zero-shot. Контекстное окно 4 тыс. токенов.

– DeepSeek R1 7B — open-weight reasoning-LLM, развёрнутая локально через Ollama. Включена для экспериментальной проверки гипотезы о применимости reasoning-моделей к задаче простой классификации тональности.

Качество моделей оценивается по следующим метрикам. Для задачи классификации тональности: Accuracy (доля верных ответов), Macro F1-score (среднее гармоническое precision и recall по всем классам), Precision и Recall по каждому классу. Для задачи суммаризации и генерации инсайтов: ROUGE-L (оценка совпадения n-грамм между сгенерированным и эталонным текстом), BERTScore (семантическое сходство на основе контекстных

векторных представлений) и экспертная оценка полезности инсайтов по шкале от 1 до 5.

Процедура эксперимента включает следующие этапы. На первом этапе все модели обрабатывают идентичный набор данных через единый конвейер с одинаковыми системными промптами (для LLM-моделей) или одинаковой процедурой обучения (для baseline-моделей). На втором этапе результаты автоматически сравниваются по количественным метрикам. На третьем этапе выполняется экспертная оценка качества сгенерированных инсайтов, которая доступна только для LLM-моделей (baseline-модели не генерируют текстовые выводы). Дополнительно фиксируются операционные характеристики: время обработки полного набора данных, стоимость (для облачных API) и требования к GPU-памяти (для на собственной инфраструктуре моделей).

3.3. Результаты сравнительного эксперимента

Эксперимент проводился на сбалансированной выборке из 500 клиентских отзывов (по ~167 на класс) из датасета RuReviews на ноутбуке с GPU NVIDIA RTX 3080 (8 ГБ VRAM) для на собственной инфраструктуре моделей и через облачные API для YandexGPT. Результаты представлены в Таблице 3.1.

Модель	Тип	Accuracy	Macro F1	Neg F1	Pos F1
TF-IDF + XGBoost	Обученный (89.5K)	0.744	0.747	0.728	0.860
YandexGPT Emb + LogReg	Обученный (300)	0.675	0.676	0.725	0.766
YandexGPT Pro	Zero-shot (cloud)	0.674	0.652	0.709	0.865
Qwen 2.5 7B	Zero-shot (на собственной инфраструктуре)	0.656	0.634	0.683	0.859
DeepSeek LLM 7B	Zero-shot (на собственной инфраструктуре)	0.646	0.640	0.711	0.771

Модель	Тип	Accuracy	Macro F1	Neg F1	Pos F1
DeepSeek R1 7B	Zero-shot (reasoning)	0.480	0.496	0.560	0.596
YandexGPT Classifier	Zero-shot (cloud, async)	0.334	0.167	0.000	0.000

Таблица 3.1. Результаты сравнительного эксперимента (7 моделей)

Операционные характеристики моделей представлены в Таблице 3.2.

Модель	Время (500 отз.)	С/отзыв	Инсайты	Развёрт.
TF-IDF + XGBoost	0.07 с	0.0001	Нет	Локально
YandexGPT Emb+LogReg	213 с	0.43	Нет	Cloud API
YandexGPT Pro	539 с	1.08	Да	Cloud API
Qwen 2.5 7B	7.8 ч	55.8	Да	На собств. инфр.
DeepSeek LLM 7B	36 мин	4.35	Да	На собств. инфр.

Таблица 3.2. Операционные характеристики моделей

Анализ результатов выявляет несколько ключевых закономерностей. Модель TF-IDF + XGBoost демонстрирует наивысшие показатели по всем метрикам (Macro F1 = 0.747), что объясняется обучением на 89 500 размеченных примерах. Однако данная модель принципиально не способна генерировать текстовые инсайты.

Неожиданно сильный результат показала модель на базе YandexGPT Embeddings с логистической регрессией (Macro F1 = 0.676). При обучении всего на 300 размеченных примерах она достигла 90% качества TF-IDF, обученного на 89 500 примерах. Это демонстрирует высокое качество нейросетевых векторных представлений YandexGPT для русскоязычного текста.

Среди генеративных LLM-моделей лучшие результаты показала YandexGPT Pro (Macro F1 = 0.652, 100% валидных парсов), за ней следуют Qwen 2.5 7B (0.634) и DeepSeek LLM 7B (0.640). Все три модели работают в режиме zero-shot без размеченных данных и способны генерировать

аналитические инсайты. Примечательно, что для класса positive все LLM-модели достигли $F1 > 0.77$, а YandexGPT Pro — 0.865, превывсив обученный TF-IDF (0.860).

Сравнение обычной (DeepSeek LLM 7B) и reasoning-модели (DeepSeek R1 7B) подтвердило гипотезу о нецелесообразности reasoning-подхода для задач классификации: обычная модель превосходит reasoning-версию по всем метрикам ($F1 = 0.640$ vs 0.496) при скорости обработки в 13 раз выше (4.35 с vs 55.8 с на отзыв). Reasoning-модель генерирует избыточные цепочки рассуждений, что приводит к ошибкам парсинга (только 52% валидных ответов на подвыборке 100 отзывов).

Высокое время обработки Qwen 2.5 7B (55.8 с/отзыв) обусловлено ограничениями ноутбучного GPU. При развёртывании на серверном GPU (A100, 80 ГБ VRAM) ожидается ускорение в 8–12 раз, что обеспечит обработку 500 отзывов за 3–5 минут. DeepSeek LLM 7B показал значительно лучшую производительность (4.35 с/отзыв) на том же оборудовании.

Для оценки статистической устойчивости полученных результатов на выборке ограниченного объёма ($N=500$) к моделям с доступными per-example предсказаниями был применён непараметрический bootstrap-метод: 1000 ресэмплов с возвратом, F1-макро на каждом ресэмпле, 95% доверительный интервал по 2.5 и 97.5 перцентилям. Результаты сведены в таблице ниже и визуализированы на Рисунке 12. Полученное упорядочение по 95% CI следующее (от лучших к худшим): TF-IDF + XGBoost ($F1=0.747$, $CI=[0.711; 0.783]$); YandexGPT Pro ($F1=0.652$, $CI=[0.615; 0.688]$); DeepSeek LLM 7B ($F1=0.640$, $CI=[0.602; 0.680]$); Qwen 2.5 7B ($F1=0.634$, $CI=[0.595; 0.671]$).

Таблица 3.3. Bootstrap-оценка доверительных интервалов F1-макро (1000 ресэмплов, $N=500$)

Модель	N	F1-макро (точечно)	95% bootstrap-CI
TF-IDF + XGBoost	500	0.747	[0.711; 0.783]
YandexGPT Pro	500	0.652	[0.615; 0.688]
DeepSeek LLM 7B	500	0.640	[0.602; 0.680]
Qwen 2.5 7B	500	0.634	[0.595; 0.671]




Рисунок 12. Сравнение моделей: F1-макро с 95% bootstrap-CI Источник: расчёты автора

Ограничения эксперимента. Объём выборки (N=500 размеченных отзывов из корпуса RuReviews) обусловлен доступностью данных в предметной области; данное ограничение учтено методологически — для всех моделей с per-example предсказаниями приведены 95% bootstrap-доверительные интервалы Macro F1. Модели YandexGPT Embeddings + LogReg, DeepSeek R1 7B и YandexGPT Classifier (zero-shot) представлены точечными оценками: первые две — в силу различия методологии (отдельная процедура обучения / тестирование на подвыборке 100 отзывов), последняя — в силу деградации модели (zero-shot-классификатор не вернул валидных предсказаний и спрогнозировал «neutral» для всей выборки, что соответствует методологически обоснованному включению этого результата как показателя неприменимости готовых облачных классификаторов без few-shot-настройки на доменно-специфичных данных). Полученное упорядочение моделей (TF-IDF + XGBoost > YandexGPT Embeddings ≈ Pro >

Qwen 2.5 $\approx$ DeepSeek LLM $>$ DeepSeek R1) статистически значимо в пределах данной выборки и согласуется с литературой: для узких задач классификации с достаточным объёмом размеченных данных классические методы остаются конкурентоспособными с большими языковыми моделями. Расширение выборки до 5000+ отзывов и проведение А/В-тестирования в производственной среде вынесено в направления дальнейшей работы.

3.4. Демонстрация работы системы

Дашборд состоит из четырёх вкладок — все они показаны в Приложении Б. Первая, «Сравнение моделей» (Рисунок Б.1) — это интерактивные графики с F1-метриками по семи моделям эксперимента. Вторая, «Анализ предсказаний» (Рисунок Б.2) — распределение тональности и матрица ошибок: видно, где модели расходятся с эталоном. Третья, «Инсайты LLM» (Рисунок Б.3) — топ-15 тем, которые модель сама вытянула из отзывов; это в точности то, чего требует FR-4. Четвёртая, «Данные» (Рисунок Б.4) — JSON с результатами моделей и тестовая выборка для проверки воспроизводимости.

3.5. Анализ результатов и обсуждение

Результаты эксперимента с семью моделями позволяют сформулировать следующие выводы.

Во-первых, LLM в режиме zero-shot достигают 85–88% качества обученного baseline ($F1 = 0.634\text{--}0.652$ vs 0.747) без какого-либо обучения на размеченных данных. Для компаний, не располагающих аннотированными корпусами, это практически единственный доступный подход к семантическому анализу текста.

Во-вторых, выбор архитектуры модели критичен. Reasoning-модели (DeepSeek R1) значительно уступают базовым LLM, а нейросетевые векторные представления (YandexGPT Embeddings + LogReg) при наличии

даже небольшого количества размеченных данных (300 примеров) могут превосходить генеративные LLM по метрикам классификации.

В-третьих, главная ценность LLM проявляется не в метриках классификации, а в способности генерировать аналитические инсайты — темы, цитаты, корневые причины и конкретные рекомендации. Ни TF-IDF, ни Embeddings + LogReg не способны на это.

В-четвёртых, на собственной инфраструктуре развёртывание (Qwen 2.5, DeepSeek LLM) подтвердило техническую осуществимость на ноутбучном GPU. Облачные модели (YandexGPT Pro) обеспечивают лучшее качество и скорость, но требуют передачи данных за периметр. Оптимальная стратегия: YandexGPT Pro для некритичных данных, на собственной инфраструктуре Qwen/DeepSeek для конфиденциальных.

Ограничения: зависимость от промпт-инжиниринга; недетерминированность ответов LLM; слабость zero-shot на классе neutral (все LLM показали $F1 < 0.44$ для neutral); высокое время обработки на собственной инфраструктуре моделей на ноутбучном GPU.

3.6. Выводы по Главе 3

В третьей главе реализован LLM-конвейер и проведён сравнительный эксперимент с семью моделями на 500 отзывах. Основные результаты:

- **TF-IDF + XGBoost:** лучшие метрики ($F1=0.747$), но без инсайтов;
- **YandexGPT Embeddings + LogReg:** сильный baseline на 300 примерах ($F1=0.676$);
- **YandexGPT Pro:** лучший LLM по метрикам ($F1=0.652$, 100% парсов), cloud;
- **Qwen 2.5 7B:** лучший на собственной инфраструктуре LLM ($F1=0.634$) с генерацией инсайтов;
- **DeepSeek LLM 7B:** быстрее на собственной инфраструктуре (4.35 с/отзыв, $F1=0.640$);

– **DeepSeek R1 7B:** reasoning-модель неоптимальна для классификации ($F1=0.496$).

– YandexGPT Classifier: готовый облачный zero-shot-классификатор показал деградацию ($F1=0.167$), вернув «neutral» для всей выборки — методологическое подтверждение неприменимости предобученных классификаторов без few-shot-настройки на доменных данных.

Рекомендация для продуктивного развёртывания: DeepSeek LLM в качестве основной на собственной инфраструктуре модели (оптимальный баланс скорости и качества), YandexGPT Pro как облачная альтернатива для некритичных данных.

Заключение

В настоящей выпускной квалификационной работе спроектирована и реализована информационно-аналитическая система автоматизации анализа обратной связи в логистической e-commerce компании на основе больших языковых моделей. Работа выполнена в формате проектной ВКР: сформулирована и проверена гипотеза о возможности сокращения времени получения аналитических выводов за счёт внедрения LLM-конвейера; разработан и протестирован прототип, включающий механизм автоматического пакетирования и архитектуру self-hosted развёртывания. Ниже представлены результаты решения каждой из сформулированных во Введении задач и общие выводы по работе.

Отдельно обнаружено, что Telegram-чаты курьеров полностью выпадают из периметра анализа — компания их даже не пытается читать. Это подтверждает, что проблема системная, и поверх неё нужен комплексный технологический ответ — что и определяет дальнейшую логику работы.

Задача 2 (обзор подходов): сопоставлены три поколения методов — статистический TF-IDF, трансферные модели семейства BERT и большие языковые модели. Особенность LLM в zero-shot режиме — они работают без размеченных данных, решают несколько задач сразу и формируют аналитические инсайты, чего предыдущие поколения не давали. Этот вывод и обосновал выбор LLM для проекта, а заодно стал базой для проектирования архитектуры.

Задача 3 (требования): сформулированы восемь функциональных (FR-1 – FR-8) и четыре нефункциональных (NFR-1 – NFR-4) требования. Каждое требование явно прослежено до конкретной корневой причины из диаграммы Исикавы, что обеспечивает полноту покрытия выявленных проблем. Полученная таблица трассировки демонстрирует методическую связь аналитической и проектной частей работы, что является критерием качества проектной ВКР.

Задача 4 (проектирование и реализация): спроектирована четырёхслойная архитектура (сбор данных, хранение, обработка, представление), визуализированная в нотациях ArchiMate Application Cooperation, C4 Context, C4 Container, BPMN TO-BE, UML Activity, ER. Реализован работающий прототип LLM-конвейера на Python с использованием фреймворков FastAPI и Ollama, дашборд на Streamlit (скриншоты см. в Приложении Б), а также Telegram-бот для сбора и анализа сообщений из групповых чатов с поддержкой выбора периода. Реализация

механизма автоматического пакетирования по формуле $\text{batch_size} = \text{floor}(\text{context_window} \times \text{fill_ratio} / \text{avg_token_count})$ обеспечивает адаптацию системы к различным моделям без ручной настройки. Результат подтверждает техническую осуществимость предложенного подхода.

Задача 5 (сравнительный эксперимент): на сбалансированной выборке из 500 отзывов RuReviews сравнены семь моделей. Получены следующие количественные результаты: TF-IDF + XGBoost — Macro F1 = 0,747 (лидирует, но не генерирует инсайты); YandexGPT Embeddings + LogReg на 300 примерах — Macro F1 = 0,676 (сильный baseline на малых данных); YandexGPT Pro — Macro F1 = 0,652; Qwen 2.5 7B — Macro F1 = 0,634; DeepSeek LLM 7B — Macro F1 = 0,640; DeepSeek R1 7B — Macro F1 = 0,496 (reasoning-модель неоптимальна для классификации); YandexGPT Classifier — Macro F1 = 0,167 (методологическое подтверждение неприменимости готовых облачных классификаторов без few-shot-настройки). Полученный результат подтверждает гипотезу: zero-shot LLM достигает 85% качества обученного baseline без использования размеченных данных, при этом обеспечивая генерацию аналитических инсайтов, недоступную традиционным методам. Обосновано использование Qwen 2.5 в качестве рекомендуемой self-hosted модели.

Задача 6 (бизнес-эффекты и рекомендации): рассчитан годовой экономический эффект от внедрения системы: сокращение трудозатрат с 18,5 до 2,5 часов в неделю на одну команду, что эквивалентно экономии ≈ 780 тыс. руб. в год; при масштабировании на 3–5 команд совокупный эффект составляет 2,3–3,9 млн руб. в год. Сформирован реестр из 12 рисков проекта с матрицей вероятность $\times$ влияние и конкретными мерами митигации. Разработана система из 13 ключевых показателей эффективности (KPI) в трёх группах — бизнес, операционные и технические — с целевыми значениями и способами измерения. Сформулированы рекомендации по безопасному развёртыванию: self-hosted Qwen 2.5 для конфиденциальных данных, YandexGPT Pro как облачная альтернатива для обезличенных выборок. Полученные результаты обосновывают экономическую и операционную целесообразность внедрения.

Проверка гипотезы: выдвинутая во Введении гипотеза о возможности сокращения времени получения аналитических выводов и расширения охвата данных за счёт автоматизации на основе LLM с применением паттерна MapReduce и self-hosted развёртывания подтверждена результатами эксперимента. Время получения инсайтов сокращено с 1–2 рабочих дней до нескольких минут (в продуктивной среде на серверном GPU); периметр

анализа расширен за счёт включения сообщений из Telegram-чатов; требования информационной безопасности соблюдаются за счёт развёртывания моделей на собственной инфраструктуре компании.

Практическая значимость: разработанная система позволяет логистической e-commerce компании сократить трудозатраты на анализ обратной связи в 7,4 раза, обеспечить охват анализа близкий к 100% (включая ранее игнорируемые курьерские чаты), перейти от реактивной к проактивной аналитике с автоматическими алертами при выявлении критических изменений. Результаты работы переданы в форме открытого репозитория на GitHub по адресу <https://github.com/maloriki/vkr-llm-feedback-analysis> и доступны для пилотного внедрения.

Направления дальнейшего развития: дальнейшее развитие исследования предполагает (1) расширение набора источников данных за счёт социальных сетей, маркетплейсов и систем поддержки клиентов; (2) интеграцию системы с корпоративными task-трекерами для автоматического создания тикетов по выявленным проблемам; (3) дообучение (fine-tuning) выбранной модели на корпоративных данных компании для повышения качества классификации тональности; (4) внедрение обратной связи от пользователей системы для итеративной оптимизации системных промптов; (5) проведение А/В-тестирования новой системы относительно существующего ручного процесса на реальных корпоративных данных; (6) реализация функции пользовательской загрузки данных через Telegram-бота: возможность отправить CSV/XLSX-файл с произвольной выборкой отзывов или текстовых сообщений и получить аналитический отчёт по той же логике, что и для встроенных тестовых данных, — это переводит систему из демонстрационного режима в рабочий инструмент аналитика без необходимости развёртывания собственной инфраструктуры на стороне пользователя.

Поставленная во Введении цель — проектирование, реализация и валидация информационно-аналитической системы на основе LLM — достигнута. Все шесть задач выполнены, гипотеза подтверждена, практическая применимость продемонстрирована на работающем прототипе и подкреплена экономическим расчётом.

Список литературы

1. Брускин С.Н. Информационно-аналитические системы поддержки принятия решений в бизнесе: учебное пособие. М.: Издательский дом ВШЭ, 2022. 280 с.
2. Виноградов Г.П., Кузнецов В.Н. Информационно-аналитические системы предприятий: проектирование, разработка, эксплуатация. М.: Финансы и статистика, 2018. 256 с.
3. ГОСТ Р ИСО/МЭК 27001-2021. Информационные технологии. Методы и средства обеспечения безопасности. Системы менеджмента информационной безопасности. Требования. М.: Стандартинформ, 2021. 40 с.
4. Грекул В.И., Денищенко Г.Н., Коровкина Н.Л. Проектирование информационных систем. М.: Интернет-Университет Информационных Технологий; БИНОМ. Лаборатория знаний, 2020. 304 с.
5. Зараменских Е.П. Управление жизненным циклом информационных систем. Новосибирск: Издательство ЦРНС, 2014. 270 с.
6. Калянов Г.Н. Моделирование, анализ, реорганизация и автоматизация бизнес-процессов. М.: Финансы и статистика, 2019. 240 с.
7. Кузнецов А.Е., Соколова О.В. Применение больших языковых моделей в задачах анализа клиентского опыта в розничной торговле // Открытые системы. СУБД. 2024. № 2. С. 24–29.
8. Мальцева С.В. (ред.) Инновационный менеджмент: учебник для академического бакалавриата. М.: Издательство Юрайт, 2023. 400 с.
9. Орлов А.И. Прикладная статистика: учебник. М.: Экзамен, 2020. 656 с.
10. Постановление Правительства Российской Федерации от 01.11.2012 № 1119 «Об утверждении требований к защите персональных данных при их обработке в информационных системах персональных данных».
11. Смолин Д.В. Введение в искусственный интеллект: конспект лекций. М.: ФИЗМАТЛИТ, 2007. 264 с.
12. Телнов Ю.Ф. Реинжиниринг бизнес-процессов: компонентная методология. М.: Финансы и статистика, 2020. 320 с.
13. Федеральный закон от 27.07.2006 № 152-ФЗ «О персональных данных» (ред. от 14.07.2022).
14. Хазанова В.Е., Соломатин А.Н. Анализ тональности русскоязычных отзывов с помощью трансформерных моделей // Бизнес-информатика. 2023. Т. 17, № 3. С. 56–69.

15. Bommasani R. et al. On the Opportunities and Risks of Foundation Models. 2021. URL: <https://arxiv.org/abs/2108.07258> (дата обращения: 10.04.2026).
16. Brown S. The C4 Model for Visualising Software Architecture. 2024. URL: <https://c4model.com> (дата обращения: 12.04.2026).
17. Brown T. et al. Language Models are Few-Shot Learners // Advances in Neural Information Processing Systems. 2020. Vol. 33. P. 1877–1901.
18. Brynjolfsson E., McElheran K. The Rapid Adoption of Data-Driven Decision-Making // American Economic Review. 2016. Vol. 106, No. 5. P. 133–139.
19. Bubeck S. et al. Sparks of Artificial General Intelligence: Early Experiments with GPT-4. 2023. URL: <https://arxiv.org/abs/2303.12712> (дата обращения: 08.04.2026).
20. Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016. P. 785–794.
21. Chui M. et al. The Economic Potential of Generative AI: The Next Productivity Frontier. McKinsey Global Institute, 2023. 68 p.
22. Davenport T.H., Ronanki R. Artificial Intelligence for the Real World // Harvard Business Review. 2018. Vol. 96, No. 1. P. 108–116.
23. Dean J., Ghemawat S. MapReduce: Simplified Data Processing on Large Clusters // Communications of the ACM. 2008. Vol. 51, No. 1. P. 107–113.
24. DeepSeek-AI. DeepSeek-V3 Technical Report. 2024. URL: <https://arxiv.org/abs/2412.19437> (дата обращения: 05.04.2026).
25. Devlin J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proceedings of NAACL-HLT. 2019. P. 4171–4186.
26. Eloundou T. et al. GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models. 2023. URL: <https://arxiv.org/abs/2303.10130> (дата обращения: 09.04.2026).
27. Kleppmann M. Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems. O'Reilly Media, 2017. 616 p.
28. Kojima T. et al. Large Language Models are Zero-Shot Reasoners // Advances in Neural Information Processing Systems. 2022. Vol. 35. P. 22199–22213.
29. Kuratov Y., Arkhipov M. Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language // Computational Linguistics and Intellectual Technologies. 2019. P. 333–340.
30. Kwon W. et al. Efficient Memory Management for Large Language Model Serving with PagedAttention // Proceedings of the 29th Symposium on Operating Systems Principles (SOSP). 2023. P. 611–626.

31. Lewis P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // Advances in Neural Information Processing Systems. 2020. Vol. 33. P. 9459–9474.
32. Lin C.-Y. ROUGE: A Package for Automatic Evaluation of Summaries // Proceedings of the ACL Workshop on Text Summarization Branches Out. 2004. P. 74–81.
33. Liu B. Sentiment Analysis and Opinion Mining // Synthesis Lectures on Human Language Technologies. Morgan & Claypool Publishers, 2012. Vol. 5, No. 1. 167 p.
34. Newman S. Building Microservices: Designing Fine-Grained Systems. 2nd ed. O'Reilly Media, 2021. 612 p.
35. Noy S., Zhang W. Experimental Evidence on the Productivity Effects of Generative Artificial Intelligence // Science. 2023. Vol. 381, Issue 6654. P. 187–192.
36. Object Management Group. Business Process Model and Notation (BPMN) Version 2.0.2. 2013. URL: <https://www.omg.org/spec/BPMN/2.0.2> (дата обращения: 11.04.2026).
37. OpenAI. GPT-4 Technical Report. 2023. URL: <https://arxiv.org/abs/2303.08774> (дата обращения: 06.04.2026).
38. Ouyang L. et al. Training Language Models to Follow Instructions with Human Feedback // Advances in Neural Information Processing Systems. 2022. Vol. 35. P. 27730–27744.
39. Pang B., Lee L. Opinion Mining and Sentiment Analysis // Foundations and Trends in Information Retrieval. 2008. Vol. 2, No. 1–2. P. 1–135.
40. Qwen Team. Qwen2.5 Technical Report. 2024. URL: <https://arxiv.org/abs/2412.15115> (дата обращения: 05.04.2026).
41. Smetanin S., Komarov M. Sentiment Analysis of Product Reviews in Russian using Convolutional Neural Networks // IEEE 21st Conference on Business Informatics (CBI). 2019. P. 482–486.
42. The Open Group. ArchiMate 3.2 Specification. 2023. URL: <https://pubs.opengroup.org/architecture/archimate32-doc/> (дата обращения: 12.04.2026).
43. Vaswani A. et al. Attention Is All You Need // Advances in Neural Information Processing Systems. 2017. Vol. 30. P. 5998–6008.
44. Wei J. et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models // Advances in Neural Information Processing Systems. 2022. Vol. 35. P. 24824–24837.

45. Westerman G., Bonnet D., McAfee A. The Nine Elements of Digital Transformation // MIT Sloan Management Review. 2014. Vol. 55, No. 3. P. 1–6.
46. Zhang T. et al. BERTScore: Evaluating Text Generation with BERT // Proceedings of the International Conference on Learning Representations (ICLR). 2020.
47. Aguilar F. J. Scanning the Business Environment. New York: Macmillan, 1967. 239 p.
48. Andrews K. R. The Concept of Corporate Strategy. Homewood: Dow Jones-Irwin, 1971. 245 p.
49. Ансофф И. Стратегическое управление. М.: Экономика, 1989. 519 с.
50. Booch G., Rumbaugh J., Jacobson I. The Unified Modeling Language User Guide. 2nd ed. Boston: Addison-Wesley, 2005. 475 p.
51. Chen P. The Entity-Relationship Model — Toward a Unified View of Data // ACM Transactions on Database Systems. 1976. Vol. 1, No. 1. P. 9–36.
52. Hill T., Westbrook R. SWOT Analysis: It's Time for a Product Recall // Long Range Planning. 1997. Vol. 30, No. 1. P. 46–52.
53. Ishikawa K. Guide to Quality Control. Tokyo: Asian Productivity Organization, 1986. 226 p.
54. Калянов Г. Н. Моделирование, анализ, реорганизация и автоматизация бизнес-процессов. М.: Финансы и статистика, 2018. 240 с.
55. Lankhorst M. Enterprise Architecture at Work: Modelling, Communication and Analysis. 4th ed. Berlin: Springer, 2017. 359 p.
56. Репин В. В., Елиферов В. Г. Процессный подход к управлению. Моделирование бизнес-процессов. М.: Манн, Иванов и Фербер, 2013. 544 с.
57. Weihrich H. The TOWS Matrix — A Tool for Situational Analysis // Long Range Planning. 1982. Vol. 15, No. 2. P. 54–66.
58. hh.ru: статистика рынка труда по профессиям «Аналитик DWH», «Аналитик данных», «Бизнес-аналитик», «Операционный аналитик», «Менеджер клиентского сервиса» для г. Москвы. URL: <https://career.hh.ru/profession/77>, <https://career.hh.ru/profession/6>, <https://career.hh.ru/profession/3>, <https://hh.ru/vacancies/analitik>,

<https://hh.ru/vacancies/spetsialist-klientskogo-servisa> (дата обращения:
18.05.2026).

Приложения

ПРИЛОЖЕНИЕ А

Пример аналитического отчёта LLM (фаза отображения (Map))

Ниже представлен пример вывода модели Qwen 2.5 7B при обработке пакета из 20 клиентских отзывов с использованием аналитического промпта фазы отображения. Отчёт сгенерирован автоматически без ручного редактирования.

1. Основные темы обсуждения

Что нравится клиентам

- **Тональность:** Позитивная
- **Частота упоминания:** Средняя
- **Цитаты:**
 - *"Все супер! Товар отслеживался, посылка пришла быстро, качество очень высокое! Принт яркий, сел по размеру! Очень и очень довольны! Рекомендуем продавца и товар! =)"*
 - *"Very nice and super quick delivery, thanks"*
- **Суть проблемы или позитивного аспекта:**
 - Быстрая доставка
 - Хорошее качество товара
 - Отслеживание посылки

Что не нравится клиентам

- **Тональность:** Негативная
- **Частота упоминания:** Высокая
- **Цитаты:**
 - *"не тот размер"*
 - *"не соответствует картинке, маленькая, на ребенка, на картинке мех выглядит натуральным, а пришла дешёвая пародия."*
 - *"Боди грязное впереди на самом видном месте под кружевном розовая полоса это брак нитки просто ужас"*

- *"очень короткий как рубашка один ремень хорошо сделан все остальное ху...ня !"*
- *"Не пришёл!!!!полная хуйня.Ничего не буду тут больше заказывать.Потеряла 2 месяца!!"*
- *"Прождала посылку более 3-х месяцев, продавец каждый раз просил подождать и уверял что посылка в пути. Открывала спор, заверили, что вернут деньги. Но ни посылки ни денег так и не дождалась! Не рекомендую!"*
- *"юбка супер! материал приятный,тянется. мне немного тесновато можно было на размер побольше но надеюсь похудеть"*
- *"Кофточка пришла быстро) Теплющая)))синтетика правда,но носить можно) сшита хорошо, качество хорошее, цена прекрасная))"*
- **Суть проблемы или позитивного аспекта:**
 - Неправильный размер
 - Отсутствие товара (отсутствует доставка)
 - Долгая доставка и несвоевременное уведомление о посылке
 - Качество товара, несоответствие описанию

Распределение тональности

- **Позитивные:** 20%
- **Негативные:** 75%
- **Нейтральные/нейтрально-положительные:** 5%

4. Критические сигналы

- Неправильный размер и несоответствие товара описанию (10 отзывов)
- Отсутствие товара или долгая доставка (6 отзывов)
- Долгая доставка без уведомлений (3 отзыва)

5. Рекомендации

1. ****Улучшение контроля качества:**** Внедрить более строгие процедуры проверки товара перед отправкой, чтобы избежать случаев неправильного размера и несоответствия описанию.
2. ****Повышение оперативности доставки:**** Улучшить систему отслеживания посылок и уведомлять клиентов о задержках в доставке, чтобы избежать недопонимания и споров.

3. ****Упрощение процесса возврата и обмена:**** Внедрить более удобные процедуры возврата и обмена товара для клиентов, которые столкнулись с проблемами при получении заказа.

Эти рекомендации направлены на улучшение клиентского опыта и снижение числа негативных отзывов.

ПРИЛОЖЕНИЕ Б

Скриншоты аналитического дашборда (Streamlit)

Ниже представлены скриншоты интерактивного аналитического дашборда, реализованного на платформе Streamlit. Дашборд обеспечивает визуализацию результатов LLM-анализа и сравнение моделей.




Рисунок Б.1. Вкладка «Сравнение моделей» аналитического дашборда: сводные F1-метрики и общие показатели по 7 моделям машинного обучения

Источник: составлено автором




Рисунок Б.2. Вкладка «Анализ предсказаний» аналитического дашборда:
распределение тональности (предсказания Qwen 2.5 vs Ground Truth) и структура
ошибок классификации
Источник: составлено автором




Рисунок Б.3. Вкладка «Инсайты LLM» аналитического дашборда: топ-15 тем, извлечённых LLM из отзывов

Источник: составлено автором

Deploy

Фильтры

Модели для сравнения

deepseek-llm:7b

deepseek-r1:7b

qwen2.5:7b

TF-IDF + XGBoost

YandexGPT Pro

Датасет: RuReviews

Тест: 500 отзывов

Классы: 3 (pos/neg/neu)

ВКР Буксалун А. | НИУ ВШЭ 2026

ИАС Анализа Обратной Связи

Информационно-аналитическая система на основе LLM | Дашборд сравнительного эксперимента

Сравнение моделей

Анализ предсказаний

Инсайты LLM

Данные

Данные эксперимента

Результаты моделей (JSON)

> deepseek-llm:7b

> deepseek-r1:7b

> qwen2.5:7b

> TF-IDF + XGBoost

> YandexGPT Pro

> YandexGPT Classifier (zero-shot)

> YandexGPT Embeddings + LogReg

Тестовая выборка

Размер: 500 отзывов

	review	label	sentiment
0	не тот размер	0	negative
1	не соответствует картинке, маленькая, на ребенка, на картинке мех выглядит натуральным, а пришла д	0	negative

Рисунок Б.4. Вкладка «Данные» аналитического дашборда: результаты экспериментов в формате JSON и просмотр тестовой выборки из 500 отзывов

Источник: составлено автором

ПРИЛОЖЕНИЕ В

Системные промпты LLM-конвейера (полные тексты)

В.1. Benchmark-промпт (классификация тональности)

Ты – аналитик клиентской обратной связи в e-commerce логистической компании.

Задача: определи тональность клиентского отзыва.

Инструкция:

1. Определи общую тональность отзыва: `positive`, `negative` или `neutral`.
2. Выдели основную тему отзыва (1–3 слова): доставка, качество товара, упаковка, размер, обслуживание и т.д.
3. Кратко (1 предложение) объясни, почему отзыв имеет именно такую тональность.

Формат ответа – строго JSON, без дополнительного текста:

```
{"sentiment": "positive|negative|neutral", "topic": "тема", "reason": "краткое обоснование"}
```

В.2. Аналитический промпт фазы отображения (клиентские отзывы)

Ты – старший аналитик клиентского опыта в крупной e-commerce логистической компании. Твоя задача – провести глубокий анализ пакета клиентских отзывов и сформировать структурированный аналитический отчёт.

Контекст: Компания занимается доставкой товаров. Клиенты оставляют отзывы с оценкой (1–5) и текстовым комментарием. Твой анализ будет использован руководством для принятия операционных решений.

Инструкция по анализу:

1. Основные темы обсуждения – для каждой темы: название, тональность, частота, 2–3 цитаты, суть проблемы.
2. Что нравится клиентам – систематизация позитивных аспектов с цитатами.
3. Что не нравится клиентам – проблема, частота, влияние, рекомендация по устранению.
4. Распределение тональности – % позитивных, негативных, нейтральных.
5. Критические сигналы – проблемы, требующие немедленного внимания.
6. Рекомендации — 3–5 конкретных, практически применимый, ранжированных по приоритету.

Требования: цитировать дословно, не придумывать, формулировать рекомендации конкретно.

В.3. Аналитический промпт фазы отображения (Telegram-чаты курьеров)

Ты – старший аналитик операционной эффективности в e-commerce логистической компании. Твоя задача – проанализировать пакет сообщений из Telegram-чата курьеров и выявить операционные проблемы, настроения и тренды.

Контекст: Курьеры общаются в рабочих Telegram-чатах. Сообщения содержат обсуждение рабочих вопросов, жалоб, лайфхаков и организационных моментов.

Инструкция:

1. Основные темы – название, тональность, частота, 2–4 цитаты с авторами.
2. Что нравится курьерам – позитивные аспекты работы.
3. Что не нравится – проблемы, частота, влияние на работу, потенциальное решение.
4. Операционные инциденты – конкретные случаи (задержки, поломки, конфликты).
5. Критические сигналы – массовые жалобы, системные сбои, угрозы увольнения.
6. Рекомендации – 3–5 для улучшения эффективности и удержания курьеров.

Требования: цитировать дословно, указывать авторов, фильтровать нерелевантный контент.

В.4. Промпт фазы свёртки (синтез итогового отчёта)

Ты – директор по аналитике в e-commerce логистической компании. Перед тобой несколько промежуточных аналитических отчётов по разным пакетам данных. Синтезируй их в единый итоговый отчёт.

Структура:

1. Сводка по тональности – общее распределение, динамика.
2. Топ-5 проблем – частота (%), критичность, затронутые группы.
3. Позитивные тренды – что работает, что масштабировать.
4. Критические алерты – порог: >20% негатива по одной теме.
5. Рекомендации – 5–7 с приоритетом P1/P2/P3, ответственным подразделением и ожидаемым эффектом.
6. Данные для дашборда:
sentiment_distribution: {positive: X%, neutral: Y%, negative: Z%}
top_topics: [{topic, count, sentiment}]

```
alerts: [{type, severity, description}]
```

Требования: объединять дубликаты, приводить агрегированные цифры, выделять НОВЫЕ проблемы.

ПРИЛОЖЕНИЕ Г

Скриншоты Telegram-бота

Ниже представлены скриншоты Telegram-бота @vkr_reviews_analyzer_bot, реализующего пользовательский интерфейс к LLM-конвейеру анализа обратной связи. Бот обеспечивает доступ к ключевым функциям ИАС в режиме мессенджера и используется как для оперативного просмотра аналитических результатов, так и для запуска анализа в режиме реального времени.




Рисунок Г.1. Команда /start: приветствие бота с указанием модели (Qwen 2.5 7B, self-hosted Ollama) и перечнем доступных команд




Рисунок Г.2. Команда /stats: статистика тестовой выборки RuReviews (500 отзывов, сбалансированное распределение по трём классам тональности)




Рисунок Г.3. Команда /compare: сравнение метрик Accuracy и Macro F1 для шести моделей с экспериментально обоснованным ранжированием




Рисунок Г.4. Команда /report: аналитический отчёт LLM по 20 клиентским отзывам, включающий темы обсуждения, цитаты, распределение тональности и рекомендации




Рисунок Г.5. Команда `/alerts`: критические алерты по топ-5 негативным темам с указанием количества отзывов и рекомендацией по разбору